

Avaliação Comparativa de Embeddings e Re-ranking (Two-Stage RAG)

Estudo de Caso: 16 Manuais Técnicos de No-breaks Industriais (CM Comandos Lineares) | Hardware: NVIDIA RTX PRO 1000 Blackwell (8 GB GDDR6)

1. O Veredito: Melhores Modelos Identificados

MELHOR EMBEDDING GERAL Multilingual-E5-Large MRR@5: 0.4031 Latência: 22.9 ms VRAM: ~2.2 GB Framework: PyTorch (FP16) Maior precisão de ordenação no 1º estágio. 18× mais rápido que o baseline em nuvem da OpenAI, com custo financeiro zero.	MELHOR RERANKER PRODUÇÃO (TEMPO REAL) BGE-Reranker-v2-m3 MRR@5: 0.4982 (+23.6%) Latência: 1.16 s VRAM: ~1.2 GB Wilcoxon: p = 0.0261* Ponto ótimo na fronteira de Pareto. Avalia 20 candidatos em apenas 1.16s na GPU e coexiste na VRAM com o embedding sem swap de memória.	MAIOR COBERTURA & PRECISÃO ABSOLUTA Qwen3-Reranker-8B (Q5_K_M) Hit Rate@5: 65.6% (+10.9 p.p.) MRR@5: 0.5029 VRAM: ~5.9 GB Latência: ~6.5 s Atingiu a maior taxa de acerto de todo o estudo. Ideal para suporte especializado e diagnósticos complexos em segundo plano.
---	--	--

2. Matriz de Decisão: Comparação Direta dos Cenários de Arquitetura

Cenário de Uso	1º Estágio (Embedding)	2º Estágio (Reranker)	HR@5	MRR@5	Latência Total	VRAM Total	Custo / 1M
Produção em Tempo Real (Recomendado)	Multilingual-E5-Large	BGE-Reranker-v2-m3	57.0%	0.4982	~1.18 s	~3.4 GB (Coexistência)	\$0.00
Máxima Cobertura (Hit Rate Máximo)	Multilingual-E5-Large	Qwen3-8B (Q5_K_M)	65.6%	0.4975	~6.91 s	~5.9 GB (Serialized)	\$0.00
Máxima Precisão (MRR Absoluto)	Qwen3-Embedding-8B (Q4_K_M)	Qwen3-8B (Q5_K_M)	60.2%	0.5029	~6.48 s	~5.9 GB (Serialized)	\$0.00
SLM Compacto (Ultra Leve)	Multilingual-E5-Large	Qwen3-4B (Q4_K_M)	62.5%	0.4764	~6.23 s	~4.7 GB (Coexistência)	\$0.00
Baseline Comercial Nuvem (OpenAI)	Multilingual-E5-Large	RankGPT (gpt-4o-mini)	61.7%	0.4573	~1.74 s	0 GB (Nuvem)	~\$150.00
Baseline 1º Estágio Puro (Sem Rerank)	Multilingual-E5-Large	none	54.7%	0.4031	0.02 s	~2.2 GB	\$0.00

Resultado Científico Central: Todos os modelos locais de re-ranking (BGE-v2-m3, Qwen3-4B e Qwen3-8B) **superaram o modelo comercial da OpenAI (RankGPT gpt-4o-mini)** em MRR@5. Na base E5-Large, o ganho da OpenAI *não atingiu significância estatística* (p = 0.0510), enquanto os modelos locais comprovaram ganho com p < 0.05.

3. Principais Conclusões para o TCC

- A Eficácia do Two-Stage RAG:** O re-ranking sobre 20 candidatos elevou o MRR@5 de **0.3887 para 0.5029 (+29.4%)** na base Qwen3-8B e de **0.4031 para 0.4982 (+23.6%)** na base E5-Large.
- Resgate Expressivo de Passagens Relevantes:** O Hit Rate@5 subiu de 54.7% para **65.6% (+10.9 pontos percentuais)** com o Qwen3-8B, demonstrando que o re-ranking resgata com precisão fragmentos que estavam dispersos nas posições 6 a 20 do pool.
- Por que Modelos Locais Vencem a OpenAI?** Cross-encoders e SLMs treinados especificamente com função de perda para ranqueamento de passagens (atenção cruzada bidirecional entre tokens) superam LLMs genéricas que reordenam por indução de texto listwise via prompt.
- Viabilidade Operacional em GPU de 8 GB:** A quantização em 4 e 5 bits (Q4_K_M / Q5_K_M) viabilizou modelos de até 8 bilhões de parâmetros sem estouro de memória, com estabilidade absoluta.

4. Recomendação de Implantação para a CM Comandos Lineares

1. **Para Atendimento em Tempo Real / Assistente Técnico:** Adotar o pipeline **Multilingual-E5-Large + BGE-Reranker-v2-m3**. Tempo de resposta ponta a ponta de ~1.18 segundo, consumo de ~3.4 GB de VRAM (ambos residentes na memória gráfica), custo zero de API e garantia de que nenhum manual confidencial ou esquemático de no-break tráfegará por servidores de terceiros.
2. **Para Diagnóstico de Manutenção Corretiva Profunda:** Empregar o pipeline **Multilingual-E5-Large + Qwen3-Reranker-8B (Q5_K_M)** para consultas analíticas de falhas e alarmes críticos, alcançando a cobertura máxima de 65.6% de acertos no Top-5.