

Avaliação Científica e Tecnológica de RAG Industrial (Retrieval & Re-ranking)

Soberania de Dados e Alta Precisão em Manuais Técnicos com Modelos Locais Quantizados

Autor: João Messias Lima Pereira | Projeto de Pesquisa Científica e Tecnológica (ICT)

Hardware de Execução: NVIDIA RTX PRO 1000 Laptop GPU (8 GB GDDR6) | Intel Core Ultra 7 | 32 GB RAM

Estudo de Caso & Parceria: CM Comandos Lineares | Setembro / 2026

2. Contexto e Desafio Industrial

Cenário de Aplicação: 16 manuais de no-breaks industriais da CM Comandos Lineares cobrindo linhas monofásicas, trifásicas e sistemas de missão crítica (hospitalar, data centers e infraestrutura de transporte).


- **Vocabulário Eletrotécnico Especializado:**
 - Manuais densos com conceitos interdependentes: *bypass estático*, *retificador tiristorizado hexapolar*, *inversor IGBT*, *tensão de flutuação VRLA*, *barramento CC* e *distorção harmônica (THD)*.
 - Erros de interpretação em campo acarretam paradas catastróficas em cargas críticas protegidas.
- **Limitações Críticas de Soluções Proprietárias em Nuvem:**
 - **Soberania e Sigilo Industrial:** Inadmissibilidade de envio de manuais e esquemáticos proprietários confidenciais para servidores externos de terceiros.
 - **Custo Operacional em Escala:** Modelo "pay-per-token" inviabiliza milhões de requisições de assistência técnica continuada.
 - **Inviabilidade em Ambientes Isolados (*Air-Gapped*):** Instalações hospitalares, subestações e centros de comando operam em redes isoladas sem conexão externa à internet.
- **Requisitos de Engenharia:**
 - Operação 100% local em hardware pessoal/workstation de **8 GB de VRAM**, resposta submétrica (< 2s) e **custo zero de inferência**.

3. Metodologia Experimental e Rigor Estatístico

- **Corpus Técnico & Consultas de Teste:**
 - Documentos divididos em chunks uniformes com `SentenceSplitter(chunk_size=512, chunk_overlap=50)`.
 - **128 perguntas técnicas deduplicadas** (N_{efetivo}) cobrindo instalação, parametrização, alarmes e procedimentos corretivos.
- **Motor de Avaliação Multicamada (*Matching Engine*):**
 - i. *Contenção Estrita de Substring*: Detecção determinística de passagens canônicas (≥ 40 caracteres normalizados);
 - ii. *Similaridade Sintática RapidFuzz*: *Token Set Ratio* ($\geq 85\%$) e *Partial Ratio* ($\geq 80\%$) contra variações morfológicas;
 - iii. *Sobreposição Semântica ROUGE-L*: Avaliação da maior subsequência comum de tokens contíguos ($F_1 \geq 0.50$).
- **Validação Estatística com Rigor Científico:**
 - **Teste Pareado de Postos com Sinais de Wilcoxon** ($\alpha = 0.05$): Avaliação de significância estatística consulta a consulta.
 - **Intervalos de Confiança Bootstrap 95%** ($B = 1.000$ iterações): Quantificação de dispersão para HR@K, MRR@K, Recall@K e MAP@K.
 - **Gestão Estrita de VRAM**: Purga determinística de memória GPU (`torch.cuda.empty_cache()` , `keep_alive=0`) e isolamento físico de índices.

4. Fase 1: Avaliação de Embeddings (1º Estágio)

- **7 Modelos em Confronto:**
 - Baseline OpenAI `text-embedding-3-small` vs. 6 modelos abertos locais (Qwen3-8B/4B Q4_K_M, Multilingual-E5-Large, BGE-M3, Nomic, BERTimbau).
- **Destaque de Precisão:**
 - `multilingual-e5-large` alcançou **MRR@5 = 0.4031** com latência ultrarrápida de **22.9 ms** (FP16 na GPU).
- **Superioridade dos SLMs em 4-bit (Q4_K_M):**
 - `qwen3_8b_q4km` atingiu maior revocação (**HR@5 = 57.03%** vs. 46.88% da OpenAI; $p = 0.0029$).
 - `qwen3_4b_q4km` entregou HR@5 = 55.47% e MRR@5 = 0.3844 com **36.0 ms**.
- **Soberania com Custo Zero:**
 - SLMs locais quantizados retêm >100% da acurácia da OpenAI com **11.5x menor latência** (36 ms vs. 415 ms) e custo zero de API.



5. O Desafio: Por que um estágio de recuperação não é suficiente?

- **Limitação Estrutural dos Bi-Encoders:**

- Bi-encoders mapeiam pergunta e passagens técnicas em vetores independentes: $\vec{u} = E(q)$, $\vec{v} = E(d)$.
- A similaridade de cosseno condensa centenas de tokens em um único escalar, perdendo correlações sutis e ordenamento estrito de passos técnicos (ex.: ordem de manobra de disjuntores, intertravamentos lógicos e diferenças sutis entre famílias de no-breaks).

- **O Teto de Precisão no Top-5:**

- No 1º estágio, mesmo o melhor modelo (`e5-large`) atinge MRR@5 de 0.4031 — ou seja, na maioria das consultas, o nó mais relevante não está no primeiro posto ($K = 1$).
- Ocorrência de falsos positivos com alta sobreposição lexical mas sem contexto operacional pertinente.

- **A Solução: Arquitetura Two-Stage RAG:**

- **1º Estágio (Super-sampling $K_{\text{cand}} = 20$):** Bi-encoder recupera 20 candidatos em 20–50 ms com recall elevado (~68%).
- **2º Estágio (Re-ranking Neural):** Atenção cruzada profunda (*all-to-all cross-attention*) ou logprob softmax binário para reordenar os nós, projetando os fragmentos corretos para o Top-1 e Top-5.


6. Fase 2: Benchmark de Re-ranking Neural no Top-5

Modelo Base (1º Estágio)	Reranker (2º Estágio)	HR@5	MRR@5	Δ MRR@5	Δ HR@5	Wilcoxon (p)	Latência Re-rank
multilingual_e5_large	none (Baseline Puro)	54.7%	0.4031	—	—	Baseline	0.0 ms
multilingual_e5_large	bge_reranker_v2_m3	57.0%	0.4982	+0.0951	+2.3%	0.0261*	1164.3 ms
multilingual_e5_large	qwen3_4b_q4km	62.5%	0.4764	+0.0733	+7.8%	0.0406*	6211.0 ms
multilingual_e5_large	qwen3_8b_q5km	65.6%	0.4975	+0.0944	+10.9%	0.0023*	6894.9 ms
multilingual_e5_large	rankgpt (gpt-4o-mini)	61.7%	0.4573	+0.0542	+7.0%	0.0510	1723.0 ms
qwen3_8b_q4km	none (Baseline Puro)	57.0%	0.3887	—	—	Baseline	0.0 ms
qwen3_8b_q4km	bge_reranker_v2_m3	53.9%	0.4866	+0.0979	-3.1%	0.0038*	1145.1 ms
qwen3_8b_q4km	qwen3_4b_q4km	60.9%	0.4738	+0.0852	+3.9%	0.0049*	5181.6 ms
qwen3_8b_q4km	qwen3_8b_q5km	60.2%	0.5029	+0.1142	+3.1%	0.0001*	6424.2 ms
qwen3_8b_q4km	rankgpt (gpt-4o-mini)	57.8%	0.4663	+0.0776	+0.8%	0.0160*	1647.8 ms

Nota: $p < 0.05$ comprova significância estatística do ganho contra o baseline puro correspondente.


7. Descoberta Central: Modelos Locais Superam a OpenAI

- **Superação Sistemática do RankGPT Comercial:**
 - Todos os modelos locais (`bge_reranker_v2_m3` , `qwen3_4b` e `qwen3_8b`) superaram o `RankGPT (gpt-4o-mini)` em MRR@5.
- **Salto Histórico de Precisão:**
 - Na base Qwen3-8B, o MRR@5 saltou de **0.3887 para 0.5029 (+29.4%)** com significância estatística extrema ($p = 0.0001$).
 - Na base E5-Large, o MRR@5 subiu para **0.4982 (+23.6%)** com BGE-Reranker-v2-m3 ($p = 0.0261$).
- **Por que Modelos Locais Vencem a Nuvem?:**
 - Modelos dedicados de re-ranking (Cross-Encoders e SLMs com logprob softmax) possuem calibração estrita de probabilidade de relevância.
 - Superam a instabilidade e heurística posicional dos prompts listwise de modelos genéricos comerciais em nuvem.



8. Trade-off de Engenharia: Acurácia vs. Latência vs. VRAM

- **Análise da Fronteira de Pareto:**
 - BGE-Reranker-v2-m3 : Melhor ponto de equilíbrio de engenharia.
 - Adiciona apenas **1.14s** por consulta na GPU.
 - Consome apenas **~1.2 GB de VRAM** (folga massiva na GPU de 8 GB).
 - Entrega MRR@5 de 0.4866 a 0.4982.
- **Sweet Spot de Cobertura (Qwen3-4B Q4_K_M):**
 - Eleva o Hit Rate@5 para **62.5%** (+7.8 p.p.) com latência de ~5.1s e ~2.5 GB VRAM.
- **Teto de Precisão (Qwen3-8B Q5_K_M):**
 - Entrega cobertura máxima (**65.6% HR@5** na base E5) e maior MRR (**0.5029** na base Qwen) em 6.4s a 6.8s (~5.9 GB VRAM).



9. Recomendação de Produção: Arquitetura 100% em CPU (Sem GPU Dedicada)

Contexto da Infraestrutura de Produção

- **Servidor Corporativo Exclusivo em CPU:**
 - O servidor de produção da CM Comandos opera **exclusivamente em CPU** (sem placa gráfica aceleradora).
 - Soberania total: proibição de tráfego de manuais confidenciais para servidores em nuvem.
- **Solução Campeã Homologada:**
 - 1º Estágio com **Multilingual-E5-Large (ONNX INT8)**.
 - Acelerado nativamente via instruções vetoriais **AVX-512 / VNNI** da CPU.
- **Custo e Segurança Operacional:**
 - **Custo zero de API** e blindagem total de segredos industriais em rede local (*air-gapped*).

Métricas Comprovadas na CPU (Servidor CM Comandos)

- **Latência Ultrarrápida na CPU:**
 - Apenas **107 ms por consulta** na CPU pura.
 - **3,9x mais rápido** que os 415 ms da API da OpenAI em nuvem!
- **Consumo Mínimo de Memória:**
 - **< 1.5 GB de RAM** (perfeitamente estável e viável em qualquer VM modesta).
- **Precisão Superior ao Baseline Comercial:**
 - **MRR@5 de 0.4031** (já superior aos 0.3840 da OpenAI `text-embedding-3-small`).
- **Prontidão para Atendimento em Tempo Real:**
 - Resposta instantânea (< 200 ms) para técnicos de campo e suporte.

Veredito de Engenharia: O **Multilingual-E5-Large (ONNX INT8)** é a recomendação definitiva para o servidor de produção da CM Comandos: velocidade de 107 ms e precisão superior à nuvem, operando 100% em CPU sem custos de acelerador ou API.

10. Estratégias Complementares e Limites de Re-ranking na CPU

Limites na CPU: Por que SLMs Foram Descartados

- **Inviabilidade de SLMs Generativos na CPU:**
 - Modelos generativos de 4B e 8B (`Qwen3-Reranker`) exigem de **20s a 40s por consulta** na CPU pura.
 - Latência proibitiva que inviabiliza completamente o uso em atendimento interativo e suporte em tempo real.
- **Reserva de Capacidade Computacional:**
 - Descartar SLMs na CPU evita enfileiramento e mantém o servidor responsivo para múltiplos técnicos simultâneos.

Busca Híbrida Leve (Altamente Recomendada) 🏆

- **Fusão Densa + Léxica via RRF:**
 - `Multilingual-E5-Large (ONNX INT8)` + `BM25` via *Reciprocal Rank Fusion*.
 - Captura códigos de falha (ex.: "F07", "E-12") e números de peças com latência adicional de **apenas ~5 ms na CPU** (~112 ms total).

Opção com Re-ranking Neural Leve (Se Necessário) ⚡

- **Cross-Encoder Compacto em CPU:**
 - `BGE-Reranker-v2-m3 (ONNX INT8)` restrito a um pool pequeno ($K_{\text{cand}} = 5$ nós).
 - Atinge latência de **~1.5s a 1.8s na CPU** mantendo consumo < 2.5 GB RAM.

Recomendação Final: A Busca Híbrida (E5-Large ONNX + BM25) fornece o melhor trade-off na CPU: máxima precisão léxica e semântica com latência de apenas ~112 ms, sem gargalos computacionais.

11. Impacto do Projeto de ICT e Próximos Passos

- **Principais Conquistas e Validações Científicas:**

- **Quebra de Paradigma Tecnológico:** Comprovação com rigor estatístico (Wilcoxon $p < 0.05$) de que modelos abertos locais superam soluções comerciais proprietárias em documentações eletrotécnicas.
- **Viabilidade Comprovada em CPU Pura:** Homologação do Multilingual-E5-Large (ONNX INT8) operando em apenas **107 ms na CPU** (< 1.5 GB RAM), eliminando a dependência de GPUs caras.
- **Soberania Integral & Custo Zero:** Blindagem de segredos industriais e manuais confidenciais de no-breaks da CM Comandos sem dependência de nuvem.

- **Próximos Passos Tecnológicos (Foco em CPU):**

- **Validação e Testes de Carga em CPU Corporativa:** Testes de concorrência simultânea do pipeline E5-Large ONNX INT8 + BM25 na infraestrutura de servidores da CM Comandos.
- **Pipeline de Geração Leve (3º Estágio):** Avaliação de modelos geradores compactos quantizados eficientes em CPU para síntese de respostas com citação exata de páginas dos manuais.
- **Piloto Operacional Integrado:** Disponibilização da ferramenta para homologação prática com técnicos de campo e equipe de assistência da CM Comandos Lineares.

Perguntas & Discussão

Avaliação Científica e Tecnológica de RAG Industrial (Retrieval & Re-ranking)

Autor: João Messias Lima Pereira

Linha de Pesquisa: Projeto de Pesquisa Científica e Tecnológica (ICT)

Instituições: Universidade & CM Comandos Lineares

Hardware de Referência: Intel Core Ultra 7 (CPU) & NVIDIA RTX PRO 1000 (8 GB GDDR6)

Repositório, códigos-fonte, pipelines e relatórios consolidados disponíveis para auditoria técnica.