

# Avaliação de Re-ranking Neural em Dois Estágios (Two-Stage RAG)

## Otimização da Precisão em Manuais Técnicos Industriais com Modelos Quantizados Locais

**Trabalho de Conclusão de Curso (TCC) — Engenharia de Software / Ciência da Computação**

*Hardware de Execução:* NVIDIA RTX PRO 1000 Blackwell (8 GB GDDR6) | Intel Core Ultra 7 265H | 32 GB RAM

*Estudo de Caso:* 16 Manuais de No-breaks Industriais — CM Comandos Lineares

# 1. Motivação: Limitações do RAG em Estágio Único

---

- **O Desafio do Jargão Industrial:**

- Manuais técnicos contêm termos como *bypass estático*, *retificador tiristorizado*, *inversor IGBT*, *tensão de flutuação VRLA*.
- Bi-encoders de 1º estágio operam em representação vetorial independente, perdendo nuances contextuais finas entre a pergunta e o fragmento.

- **A Solução Two-Stage RAG:**

- **1º Estágio (Super-sampling  $K_{\text{cand}} = 20$ ):** Recupera rapidamente uma vizinhança ampla de alta revocação (*recall*).
- **2º Estágio (Re-ranking):** Aplica atenção cruzada profunda (*all-to-all token attention*) ou inferência de probabilidade condicional para reorganizar o Top-5.

- **Hipótese Central de Pesquisa:**

- Modelos locais quantizados (Q4\_K\_M / Q5\_K\_M) e Cross-Encoders dedicados locais atingem ganhos estatisticamente significantes sobre o baseline puro e superam APIs comerciais proprietárias com custo zero.

## 2. Modelos e Arquiteturas Avaliados

---

### 1º Estágio (Recuperação Vetorial Densa - Top-2 do Benchmark Prévio)

- `qwen3_8b_q4km` : Qwen3-Embedding-8B quantizado em Q4\_K\_M (Ollama, 5.2 GB VRAM).
- `multilingual_e5_large` : Microsoft Multilingual-E5-Large em FP16 (HuggingFace, 2.2 GB VRAM).

### 2º Estágio (Reordenadores Neurais)

- **Baseline Puro ( `none` )** : Ordenação vetorial original sem modelo de 2º estágio.
- `qwen3_4b_q4km` : Qwen3-Reranker-4B (Q4\_K\_M via Ollama, logprob softmax binário).
- `qwen3_8b_q5km` : Qwen3-Reranker-8B (Q5\_K\_M via Ollama, logprob softmax binário).
- `bge_reranker_v2_m3` : BAAI BGE-Reranker-v2-m3 Cross-Encoder (HuggingFace PyTorch).
- `rankgpt` : RankGPT baseado em OpenAI `gpt-4o-mini` (Prompt listwise via API em nuvem).

## 3. Metodologia Experimental e Rigor Estatístico

---

- **Corpus & Consultas:**

- 16 manuais de no-breaks industriais divididos em chunks de 512 tokens (overlap 50).
- 128 perguntas de teste independentes (deduplicadas de 132 originais).

- **Matching Engine em 3 Camadas:**

- i. *Contenção Estrita de Substring* (trechos  $\geq 40$  chars normalizados);
- ii. *RapidFuzz Token Set Ratio* ( $\geq 85\%$  similaridade ou partial ratio  $\geq 80\%$ );
- iii. *ROUGE-L Lexical Overlap* ( $F_1 \geq 0.50$ ).

- **Validação Estatística:**

- Teste pareado não-paramétrico de **Wilcoxon** ( $\alpha = 0.05$ ) sobre a variação consulta-a-consulta de MRR@5.
- Intervalos de Confiança **Bootstrap 95%** ( $B = 1.000$  iterações).

- **Gestão Estrita de VRAM:**

- Descarga obrigatória de memória GPU entre modelos ( `torch.cuda.empty_cache()` , `keep_alive=0` , `gc.collect()` ).

## 4. Tabela Geral de Resultados no Top-5 ( $K = 5$ )

| Modelo Base           | Reranker           | HR@5  | MRR@5         | $\Delta$ MRR@5 | $\Delta$ HR@5 | Wilcoxon (p) | Latência  |
|-----------------------|--------------------|-------|---------------|----------------|---------------|--------------|-----------|
| multilingual_e5_large | none               | 54.7% | <b>0.4031</b> | —              | —             | Baseline     | 0.0 ms    |
| multilingual_e5_large | bge_reranker_v2_m3 | 57.0% | <b>0.4982</b> | +0.0951        | +2.3%         | 0.0261       | 1164.3 ms |
| multilingual_e5_large | qwen3_4b_q4km      | 62.5% | <b>0.4764</b> | +0.0733        | +7.8%         | 0.0406       | 6211.0 ms |
| multilingual_e5_large | qwen3_8b_q5km      | 65.6% | <b>0.4975</b> | +0.0944        | +10.9%        | 0.0023       | 6894.9 ms |
| multilingual_e5_large | rankgpt            | 61.7% | <b>0.4573</b> | +0.0542        | +7.0%         | 0.0510       | 1723.0 ms |
| qwen3_8b_q4km         | none               | 57.0% | <b>0.3887</b> | —              | —             | Baseline     | 0.0 ms    |
| qwen3_8b_q4km         | bge_reranker_v2_m3 | 53.9% | <b>0.4866</b> | +0.0979        | -3.1%         | 0.0038       | 1145.1 ms |
| qwen3_8b_q4km         | qwen3_4b_q4km      | 60.9% | <b>0.4738</b> | +0.0852        | +3.9%         | 0.0049       | 5181.6 ms |
| qwen3_8b_q4km         | qwen3_8b_q5km      | 60.2% | <b>0.5029</b> | +0.1142        | +3.1%         | 0.0001       | 6424.2 ms |
| qwen3_8b_q4km         | rankgpt            | 57.8% | <b>0.4663</b> | +0.0776        | +0.8%         | 0.0160       | 1647.8 ms |

*\*Nota:  $p < 0.05$  comprova significância estatística do ganho contra o baseline puro correspondente.*

## 5. Eficácia de Recuperação: MRR@5 vs. Hit Rate@5

- **Salto Expressivo de Precisão:**

- O re-ranking elevou o MRR@5 de **0.3887** → **0.5029 (+29.4%)** na base Qwen3-8B.
- Na base E5-Large, o MRR@5 saltou de **0.4031** → **0.4980 (+23.5%)**.

- **Resgate de Documentos Relevantes:**

- O Hit Rate@5 aumentou até **+7.8 pontos percentuais** (de 54.7% para 62.5% com Qwen3-4B).

- **Top Performer Absoluto:**

- **Qwen3-8B (Q5\_K\_M)** entregou a melhor ordenação média do experimento (MRR@5 = 0.5029).

A graphic element consisting of a light blue rounded rectangle with a subtle drop shadow. Inside the rectangle, on the left, is a small icon of a document with a green checkmark. To the right of the icon, the text "Ranking MRR5 e HR5" is written in a black, sans-serif font.

## 6. Ganhos Incrementais: Todos os Modelos Locais Superam RankGPT

- **Superação da OpenAI Comercial:**

- RankGPT (gpt-4o-mini) obteve  $\Delta$  MRR@5 de **+0.0776**.
- Qwen3-4B (Q4\_K\_M) obteve  $\Delta$  MRR@5 de **+0.0852**.
- BGE-v2-m3 obteve  $\Delta$  MRR@5 de **+0.0979**.
- Qwen3-8B (Q5\_K\_M) obteve  $\Delta$  MRR@5 de **+0.1142**.

- **Por que os Modelos Locais Vencem?:**

- *Fine-tuning dedicado para relevância de passagens* supera o prompt genérico listwise da LLM.
- Logprobs em token binário ("yes"/"no") capturam calibração fina de confiança semântica.




Ganhos Incrementais MRR5

## 7. Trade-off de Engenharia: Acurácia vs. Latência

---

- **Sweet Spot de Latência ( BGE-Reranker-v2-m3 ):**
  - Adiciona apenas **1.14 segundos** por consulta para avaliar todos os 20 candidatos na GPU.
  - Atinge MRR@5 de 0.4866 (superior ao RankGPT com menos latência).
- **Sweet Spot de Cobertura ( Qwen3-4B Q4\_K\_M ):**
  - Maior Hit Rate@5 (**60.9% a 62.5%**), com latência de ~5.1s.
- **Custo Computacional do 8B:**
  - Atinge o pico de precisão (0.5029), porém com latência de ~6.4s a 6.5s por consulta.





## 8. Viabilidade Operacional e Perfil de Recursos

### Alocação de VRAM e Custo Operacional (GPU 8 GB GDDR6)

| Modelo / Pipeline          | Engine                | VRAM Alocada | Custo / 1M Queries | Dependência de Nuvem |
|----------------------------|-----------------------|--------------|--------------------|----------------------|
| BGE-Reranker-v2-m3         | HuggingFace (PyTorch) | ~1.2 GB      | \$0.00             | 100% Offline         |
| Qwen3-Reranker-4B (Q4_K_M) | Ollama (GGUF)         | ~2.5 GB      | \$0.00             | 100% Offline         |
| Qwen3-Reranker-8B (Q5_K_M) | Ollama (GGUF)         | ~5.9 GB      | \$0.00             | 100% Offline         |
| RankGPT (gpt-4o-mini)      | OpenAI Cloud API      | 0.0 GB       | ~\$150.00          | Conexão Obrigatória  |

**Conclusão de Engenharia:** Tanto o BGE-Reranker-v2-m3 quanto o Qwen3-4B operam com enorme folga de memória na GPU RTX PRO 1000 (8 GB), garantindo estabilidade e custo zero.

## 9. Recomendações Finais de Arquitetura para a CM Comandos

---

### Arquitetura de Produção Recomendada (Pipeline Híbrido)

#### 1. Cenário de Produção em Tempo Real (Baixa Latência & SLA Rígido):

- **1º Estágio:** Multilingual-E5-Large (FP16 ou ONNX INT8) *ightarrow* 22.9 ms.
- **2º Estágio:** BGE-Reranker-v2-m3 *ightarrow* 1145 ms.
- **Tempo Total:** ~1.17 segundos | **MRR@5:** 0.4866 | **VRAM Máxima:** 2.5 GB.

#### 2. Cenário de Análise Aprofundada / Suporte Especializado:

- **1º Estágio:** Qwen3-Embedding-8B (Q4\_K\_M) *ightarrow* 57.1 ms.
- **2º Estágio:** Qwen3-Reranker-8B (Q5\_K\_M) *ightarrow* 6424 ms.
- **Tempo Total:** ~6.48 segundos | **MRR@5:** 0.5029 | **HR@5:** 60.2%.

# Perguntas & Discussão Técnica

## Contribuições do TCC:

- Demonstração empírica da viabilidade de RAG Two-Stage 100% local em GPU de 8 GB.
- Confirmação de que SLMs quantizados locais superam modelos comerciais genéricos em domínio eletrotécnico.
- Código, dados e pipelines totalmente reproduzíveis.

*Obrigado!*