

Avaliação de Re-ranking Neural em Dois Estágios (Two-Stage RAG)

Otimização da Precisão em Manuais Técnicos Industriais com Modelos Quantizados Locais

Autor: João Messias Lima Pereira | Projeto de Pesquisa Científica e Tecnológica (ICT)

Hardware de Execução: NVIDIA RTX PRO 1000 Blackwell (8 GB GDDR6) | Intel Core Ultra 7 265H | 32 GB RAM

Estudo de Caso: 16 Manuais de No-breaks Industriais — CM Comandos Lineares

1. Motivação: Limitações do RAG em Estágio Único

- **O Desafio do Jargão Industrial:**

- Manuais técnicos contêm termos como *bypass estático*, *retificador tiristorizado*, *inversor IGBT*, *tensão de flutuação VRLA*.
- Bi-encoders de 1º estágio operam em representação vetorial independente, perdendo nuances contextuais finas entre a pergunta e o fragmento.

- **A Solução Two-Stage RAG:**

- **1º Estágio (Super-sampling $K_{\text{cand}} = 20$):** Recupera rapidamente uma vizinhança ampla de alta revocação (*recall*).
- **2º Estágio (Re-ranking):** Aplica atenção cruzada profunda (*all-to-all token attention*) ou inferência de probabilidade condicional para reorganizar o Top-5.

- **Hipótese Central de Pesquisa:**

- Modelos locais quantizados (Q4_K_M / Q5_K_M) e Cross-Encoders dedicados locais atingem ganhos estatisticamente significantes sobre o baseline puro e superam APIs comerciais proprietárias com custo zero.

2. Modelos e Arquiteturas Avaliados

1º Estágio (Recuperação Vetorial Densa - Top-2 do Benchmark Prévio)

- `qwen3_8b_q4km` : Qwen3-Embedding-8B quantizado em Q4_K_M (Ollama, 5.2 GB VRAM).
- `multilingual_e5_large` : Microsoft Multilingual-E5-Large em FP16 (HuggingFace, 2.2 GB VRAM).

2º Estágio (Reordenadores Neurais)

- **Baseline Puro (`none`)** : Ordenação vetorial original sem modelo de 2º estágio.
- `qwen3_4b_q4km` : Qwen3-Reranker-4B (Q4_K_M via Ollama, logprob softmax binário).
- `qwen3_8b_q5km` : Qwen3-Reranker-8B (Q5_K_M via Ollama, logprob softmax binário).
- `bge_reranker_v2_m3` : BAAI BGE-Reranker-v2-m3 Cross-Encoder (HuggingFace PyTorch).
- `rankgpt` : RankGPT baseado em OpenAI `gpt-4o-mini` (Prompt listwise via API em nuvem).

3. Metodologia Experimental e Rigor Estatístico

- **Corpus & Consultas:**

- 16 manuais de no-breaks industriais divididos em chunks de 512 tokens (overlap 50).
- 128 perguntas de teste independentes (deduplicadas de 132 originais).

- **Matching Engine em 3 Camadas:**

- i. *Contenção Estrita de Substring* (trechos ≥ 40 chars normalizados);
- ii. *RapidFuzz Token Set Ratio* ($\geq 85\%$ similaridade ou partial ratio $\geq 80\%$);
- iii. *ROUGE-L Lexical Overlap* ($F_1 \geq 0.50$).

- **Validação Estatística:**

- Teste pareado não-paramétrico de **Wilcoxon** ($\alpha = 0.05$) sobre a variação consulta-a-consulta de MRR@5.
- Intervalos de Confiança **Bootstrap 95%** ($B = 1.000$ iterações).

- **Gestão Estrita de VRAM:**

- Descarga obrigatória de memória GPU entre modelos (`torch.cuda.empty_cache()` , `keep_alive=0` , `gc.collect()`).


4. Tabela Geral de Resultados no Top-5 ($K = 5$)

Modelo Base	Reranker	HR@5	MRR@5	Δ MRR@5	Δ HR@5	Wilcoxon (p)	Latência
multilingual_e5_large	none	54.7%	0.4031	—	—	Baseline	0.0 ms
multilingual_e5_large	bge_reranker_v2_m3	57.0%	0.4982	+0.0951	+2.3%	0.0261	1164.3 ms
multilingual_e5_large	qwen3_4b_q4km	62.5%	0.4764	+0.0733	+7.8%	0.0406	6211.0 ms
multilingual_e5_large	qwen3_8b_q5km	65.6%	0.4975	+0.0944	+10.9%	0.0023	6894.9 ms
multilingual_e5_large	rankgpt	61.7%	0.4573	+0.0542	+7.0%	0.0510	1723.0 ms
qwen3_8b_q4km	none	57.0%	0.3887	—	—	Baseline	0.0 ms
qwen3_8b_q4km	bge_reranker_v2_m3	53.9%	0.4866	+0.0979	-3.1%	0.0038	1145.1 ms
qwen3_8b_q4km	qwen3_4b_q4km	60.9%	0.4738	+0.0852	+3.9%	0.0049	5181.6 ms
qwen3_8b_q4km	qwen3_8b_q5km	60.2%	0.5029	+0.1142	+3.1%	0.0001	6424.2 ms
qwen3_8b_q4km	rankgpt	57.8%	0.4663	+0.0776	+0.8%	0.0160	1647.8 ms

**Nota: $p < 0.05$ comprova significância estatística do ganho contra o baseline puro correspondente.*


5. Eficácia de Recuperação: MRR@5 vs. Hit Rate@5

- **Salto Expressivo de Precisão:**
 - O re-ranking elevou o MRR@5 de **0.3887** → **0.5029 (+29.4%)** na base Qwen3-8B.
 - Na base E5-Large, o MRR@5 saltou de **0.4031** → **0.4980 (+23.5%)**.
- **Resgate de Documentos Relevantes:**
 - O Hit Rate@5 aumentou até **+7.8 pontos percentuais** (de 54.7% para 62.5% com Qwen3-4B).
- **Top Performer Absoluto:**
 - **Qwen3-8B (Q5_K_M)** entregou a melhor ordenação média do experimento (MRR@5 = 0.5029).




6. Ganhos Incrementais: Todos os Modelos Locais Superam RankGPT

- **Superação da OpenAI Comercial:**
 - RankGPT (gpt-4o-mini) obteve Δ MRR@5 de **+0.0776**.
 - Qwen3-4B (Q4_K_M) obteve Δ MRR@5 de **+0.0852**.
 - BGE-v2-m3 obteve Δ MRR@5 de **+0.0979**.
 - Qwen3-8B (Q5_K_M) obteve Δ MRR@5 de **+0.1142**.
- **Por que os Modelos Locais Vencem?:**
 - *Fine-tuning dedicado para relevância de passagens* supera o prompt genérico listwise da LLM.
 - Logprobs em token binário ("yes"/"no") capturam calibração fina de confiança semântica.



7. Trade-off de Engenharia: Acurácia vs. Latência

- **Sweet Spot de Latência (BGE-Reranker-v2-m3):**
 - Adiciona apenas **1.14 segundos** por consulta para avaliar todos os 20 candidatos na GPU.
 - Atinge MRR@5 de 0.4866 (superior ao RankGPT com menos latência).
- **Sweet Spot de Cobertura (Qwen3-4B Q4_K_M):**
 - Maior Hit Rate@5 (**60.9% a 62.5%**), com latência de ~5.1s.
- **Custo Computacional do 8B:**
 - Atinge o pico de precisão (0.5029), porém com latência de ~6.4s a 6.5s por consulta.



8. Viabilidade Operacional e Perfil de Recursos

Alocação de VRAM e Custo Operacional (GPU 8 GB GDDR6)

Modelo / Pipeline	Engine	VRAM Alocada	Custo / 1M Queries	Dependência de Nuvem
BGE-Reranker-v2-m3	HuggingFace (PyTorch)	~1.2 GB	\$0.00	100% Offline
Qwen3-Reranker-4B (Q4_K_M)	Ollama (GGUF)	~2.5 GB	\$0.00	100% Offline
Qwen3-Reranker-8B (Q5_K_M)	Ollama (GGUF)	~5.9 GB	\$0.00	100% Offline
RankGPT (gpt-4o-mini)	OpenAI Cloud API	0.0 GB	~\$150.00	Conexão Obrigatória

Conclusão de Engenharia: Tanto o BGE-Reranker-v2-m3 quanto o Qwen3-4B operam com enorme folga de memória na GPU RTX PRO 1000 (8 GB), garantindo estabilidade e custo zero.

9. Recomendações Finais de Arquitetura para a CM Comandos

Arquitetura de Produção Recomendada (Pipeline Híbrido)

1. Cenário de Produção em Tempo Real (Baixa Latência & SLA Rígido):

- **1º Estágio:** Multilingual-E5-Large (FP16 ou ONNX INT8) *ightarrow* 22.9 ms.
- **2º Estágio:** BGE-Reranker-v2-m3 *ightarrow* 1145 ms.
- **Tempo Total:** ~1.17 segundos | **MRR@5:** 0.4866 | **VRAM Máxima:** 2.5 GB.

2. Cenário de Análise Aprofundada / Suporte Especializado:

- **1º Estágio:** Qwen3-Embedding-8B (Q4_K_M) *ightarrow* 57.1 ms.
- **2º Estágio:** Qwen3-Reranker-8B (Q5_K_M) *ightarrow* 6424 ms.
- **Tempo Total:** ~6.48 segundos | **MRR@5:** 0.5029 | **HR@5:** 60.2%.

Perguntas & Discussão Técnica

Contribuições da Pesquisa (ICT):

- Demonstração empírica da viabilidade de RAG Two-Stage 100% local em GPU de 8 GB.
- Confirmação de que SLMs quantizados locais superam modelos comerciais genéricos em domínio eletrotécnico.
- Código, dados e pipelines totalmente reprodutíveis.

Obrigado!