

Avaliação Científica de Re-ranking Neural em Dois Estágios (Two-Stage RAG)

Trabalho de Conclusão de Curso (TCC) — Engenharia de Software / Ciência da Computação

Estudo de Caso: Recuperação de Informação em Manuais Técnicos de No-breaks Industriais (CM Comandos Lineares)

Hardware de Execução: NVIDIA RTX PRO 1000 Blackwell Laptop GPU (8 GB GDDR6), Intel Core Ultra 7 265H CPU, 32 GB RAM

Ambiente de Inferência: Ollama (LLaMA C++ / GGML), HuggingFace Sentence-Transformers, OpenAI API (RankGPT Baseline)

Resumo do Experimento

Neste notebook avaliamos a arquitetura de **RAG em Dois Estágios** (*Two-Stage Retrieval & Re-ranking*) aplicada a 16 manuais de no-breaks industriais. O primeiro estágio recupera uma lista expandida de $K_{\text{cand}} = 20$ candidatos via bi-encoder denso. O segundo estágio emprega modelos de re-ranking (Cross-Encoders e SLMs baseados em logprobs) para reordenar os nós antes do envio ao gerador.

São avaliados:

1. Modelos de 1º Estágio (Top-2 do Benchmark de Embeddings):

- qwen3_8b_q4km (Ollama, Q4_K_M)
- multilingual_e5_large (HuggingFace / PyTorch, FP16)

2. Reordenadores Neurais de 2º Estágio:

- **Baseline Puro:** none (Top-K direto do 1º estágio sem reordenação)
- **SLM Local 4B:** dengcao/Qwen3-Reranker-4B:Q4_K_M (Ollama, binary logprob softmax)
- **SLM Local 8B:** dengcao/Qwen3-Reranker-8B:Q5_K_M (Ollama, binary logprob softmax)
- **Cross-Encoder Dedicado:** BAAI/bge-reranker-v2-m3 (HuggingFace PyTorch)
- **Baseline Comercial de Nuvem:** RankGPT baseado em gpt-4o-mini (OpenAI API via prompt listwise)