

# Avaliação Comparativa de Embeddings e Re-ranking (Two-Stage RAG)

**Autor:** João Messias Lima Pereira | **Estudo de Caso:** 16 Manuais Técnicos de No-breaks Industriais (CM Comandos Lineares) |

**Hardware:** NVIDIA RTX PRO 1000 Laptop GPU (8 GB GDDR6) & Intel Core Ultra 7 (CPU)

## 1. O Veredito: Melhores Modelos Identificados

|                                                                                                                                                                                                                                                                                                                                                                                                            |                                                                                                                                                                                                                                                                                                                                                                                |                                                                                                                                                                                                                                                                                                                                                                                        |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>🏆 <b>CAMPEÃO HOMOLOGADO (100% CPU)</b></p> <p><b>Multilingual-E5-Large (ONNX INT8)</b></p> <p><b>MRR@5:</b> 0.4031   <b>Latência CPU:</b> 107 ms (3,9x mais rápido que OpenAI)</p> <p><b>RAM:</b> &lt; 1.5 GB   <b>Zero GPU</b>   <b>Custo:</b> \$0.00</p> <p>Solução recomendada para o servidor da CM Comandos. Maior precisão no 1º estágio, soberania total e resposta instantânea em CPU pura.</p> | <p>⚡ <b>MELHOR RERANKER EM BENCHMARK</b></p> <p><b>BGE-Reranker-v2-m3</b></p> <p><b>MRR@5:</b> 0.4982 (+23.6%)   <b>Latência CPU:</b> ~1.6s (K=5)</p> <p><b>RAM:</b> &lt; 2.5 GB (ONNX INT8)   <b>Wilcoxon:</b> p = 0.0261*</p> <p>Ponto ótimo na fronteira de Pareto. Avalia candidatos sem sobrecarregar memória; viável em CPU com pool restrito (\$K_{ext{cand}}=5\$).</p> | <p>🎯 <b>MAIOR PRECISÃO EM BENCHMARK</b></p> <p><b>Qwen3-Reranker-8B (Q5_K_M)</b></p> <p><b>Hit Rate@5:</b> 65.6% (+10.9 p.p.)   <b>MRR@5:</b> 0.5029</p> <p><b>Status CPU:</b> Descartado na CPU (&gt; 25s)   <b>Uso:</b> Apenas Pesquisa</p> <p>Atingiu a maior taxa de acerto no estudo experimental. Inviável para produção em CPU em tempo real devido ao custo computacional.</p> |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

## 2. Matriz de Decisão: Comparação Direta dos Cenários de Arquitetura

| Cenário de Uso                                 | 1º Estágio (Embedding)              | 2º Estágio (Reranker)     | HR@5         | MRR@5         | Latência Total          | VRAM / RAM                        | Custo / 1M    |
|------------------------------------------------|-------------------------------------|---------------------------|--------------|---------------|-------------------------|-----------------------------------|---------------|
| <b>Produção em CPU (Recomendado CM)</b> 🏆      | <b>Multilingual-E5-Large (ONNX)</b> | <b>Busca Híbrida BM25</b> | <b>54.7%</b> | <b>0.4031</b> | <b>~0.11 s (107 ms)</b> | <b>RAM &lt; 1.5 GB (Zero GPU)</b> | <b>\$0.00</b> |
| <i>Two-Stage Rerank (Referência Benchmark)</i> | Multilingual-E5-Large               | BGE-Reranker-v2-m3        | 57.0%        | 0.4982        | ~1.18 s                 | VRAM ~3.4 GB                      | \$0.00        |
| <b>Máxima Cobertura (Hit Rate Máximo)</b> 🎯    | Multilingual-E5-Large               | Qwen3-8B (Q5_K_M)         | <b>65.6%</b> | 0.4975        | ~6.91 s                 | ~5.9 GB (Serializado)             | \$0.00        |
| <b>Máxima Precisão (MRR Absoluto)</b> 📈        | Qwen3-Embedding-8B (Q4_K_M)         | Qwen3-8B (Q5_K_M)         | 60.2%        | <b>0.5029</b> | ~6.48 s                 | ~5.9 GB (Serializado)             | \$0.00        |
| <b>SLM Compacto (Ultra Leve)</b> 💡             | Multilingual-E5-Large               | Qwen3-4B (Q4_K_M)         | 62.5%        | 0.4764        | ~6.23 s                 | ~4.7 GB (Coexistência)            | \$0.00        |
| <i>Baseline Comercial Nuvem (OpenAI)</i>       | Multilingual-E5-Large               | RankGPT (gpt-4o-mini)     | 61.7%        | 0.4573        | ~1.74 s                 | 0 GB (Nuvem)                      | ~\$150.00     |
| <i>Baseline 1º Estágio Puro (Sem Rerank)</i>   | Multilingual-E5-Large               | none                      | 54.7%        | 0.4031        | 0.02 s                  | ~2.2 GB                           | \$0.00        |

**Resultado Científico Central:** Todos os modelos locais de re-ranking (BGE-v2-m3, Qwen3-4B e Qwen3-8B) **superaram o modelo comercial da OpenAI (RankGPT gpt-4o-mini)** em MRR@5. Na base E5-Large, o ganho da OpenAI *não atingiu significância estatística* (p = 0.0510), enquanto os modelos locais comprovaram ganho com p < 0.05.

### 3. Principais Conclusões para o Projeto de Pesquisa (ICT)

- **A Eficácia do Two-Stage RAG:** O re-ranking sobre 20 candidatos elevou o MRR@5 de **0.3887 para 0.5029 (+29.4%)** na base Qwen3-8B e de **0.4031 para 0.4982 (+23.6%)** na base E5-Large.
- **Resgate Expressivo de Passagens Relevantes:** O Hit Rate@5 subiu de 54.7% para **65.6% (+10.9 pontos percentuais)** com o Qwen3-8B, demonstrando que o re-ranking resgata com precisão fragmentos que estavam dispersos nas posições 6 a 20 do pool.
- **Por que Modelos Locais Vencem a OpenAI?** Cross-encoders e SLMs treinados especificamente com função de perda para ranqueamento de passagens (atenção cruzada bidirecional entre tokens) superam LLMs genéricas que reordenam por indução de texto listwise via prompt.
- **Viabilidade Operacional em Workstation e CPU Corporativa:** A quantização em 4 e 5 bits viabilizou modelos de até 8B parâmetros em GPU de 8 GB, enquanto a execução em ONNX INT8 permitiu latência sub-110 ms em CPU comum sem acelerador gráfico.

### 4. Recomendação de Implantação para a CM Comandos Lineares (100% em CPU)

#### Diretriz Arquitetural Exclusiva em CPU (Servidor de Produção CM Comandos):

O servidor corporativo de produção opera **estritamente em CPU** (sem aceleradores gráficos dedicados). Testes empíricos no corpus da CM Comandos homologam o **Multilingual-E5-Large (ONNX INT8)** atingindo **107 ms na CPU** (< 1.5 GB RAM) com MRR@5 de **0.4031** — superando a API OpenAI Cloud (0.3840 a 415 ms) com 1/4 da latência e custo financeiro zero. SLMs generativos de 4B e 8B (Qwen3-Reranker) foram *formalmente descartados na CPU* por latência proibitiva (> 20s a 40s).

1. **Solução Campeã Homologada: Busca Híbrida Leve em CPU 🏆:** Adotar o pipeline com **Multilingual-E5-Large (ONNX INT8)** integrado à busca léxica **BM25** via *Reciprocal Rank Fusion (RRF)*. *Latência Total na CPU: ~112 ms* (107 ms vetorial + 5 ms léxico) | *RAM: < 1.5 GB* | *Zero GPU* | *Custo: \$0.00*. Captura com precisão códigos de falhas, números de componentes e termos eletrotécnicos com resposta instantânea e soberania total.
2. **Descarte Formal de SLMs Generativos na CPU 🚫:** Os modelos Qwen3-Reranker-4B e 8B exigem de 20 a 40 segundos por consulta em CPU pura. Foram integralmente descartados para o ambiente de produção para garantir atendimento síncrono e capacidade multiusuário.
3. **Opção Alternativa com Re-ranking Neural Leve (Se Necessário) ⚡:** Caso seja indispensável reordenação por atenção cruzada em chamados complexos, empregar **Multilingual-E5-Large (ONNX INT8)** + Cross-Encoder **BGE-Reranker-v2-m3 (ONNX INT8)** com pool restrito a **\$K\_{ext{cand}} = 5\$ nós**. *Latência Total na CPU: ~1.5s a 1.8s* | *Zero GPU* | *RAM: < 2.5 GB*. Alternativa viável sem extrapolar limites toleráveis.