

Avaliação Comparativa de Embeddings e Re-ranking (Two-Stage RAG)

Autor: João Messias Lima Pereira | **Estudo de Caso:** 16 Manuais Técnicos de No-breaks Industriais (CM Comandos Lineares) |

Hardware: NVIDIA RTX PRO 1000 Laptop GPU (8 GB GDDR6) & Intel Core Ultra 7 (CPU)

1. O Veredito: Melhores Modelos Identificados

MELHOR EMBEDDING GERAL Multilingual-E5-Large MRR@5: 0.4031 Latência: 22.9 ms VRAM: ~2.2 GB Framework: PyTorch (FP16) Maior precisão de ordenação no 1º estágio. 18× mais rápido que o baseline em nuvem da OpenAI, com custo financeiro zero.	MELHOR RERANKER PRODUÇÃO (TEMPO REAL) BGE-Reranker-v2-m3 MRR@5: 0.4982 (+23.6%) Latência: 1.16 s VRAM: ~1.2 GB Wilcoxon: p = 0.0261* Ponto ótimo na fronteira de Pareto. Avalia 20 candidatos em apenas 1.16s na GPU e coexiste na VRAM com o embedding sem swap de memória.	MAIOR COBERTURA & PRECISÃO ABSOLUTA Qwen3-Reranker-8B (Q5_K_M) Hit Rate@5: 65.6% (+10.9 p.p.) MRR@5: 0.5029 VRAM: ~5.9 GB Latência: ~6.5 s Atingiu a maior taxa de acerto de todo o estudo. Ideal para suporte especializado e diagnósticos complexos em segundo plano.
--	---	---

2. Matriz de Decisão: Comparação Direta dos Cenários de Arquitetura

Cenário de Uso	1º Estágio (Embedding)	2º Estágio (Reranker)	HR@5	MRR@5	Latência Total	VRAM Total	Custo / 1M
Produção em Tempo Real (Recomendado)	Multilingual-E5-Large	BGE-Reranker-v2-m3	57.0%	0.4982	~1.18 s	~3.4 GB (Coexistência)	\$0.00
Máxima Cobertura (Hit Rate Máximo)	Multilingual-E5-Large	Qwen3-8B (Q5_K_M)	65.6%	0.4975	~6.91 s	~5.9 GB (Serialized)	\$0.00
Máxima Precisão (MRR Absoluto)	Qwen3-Embedding-8B (Q4_K_M)	Qwen3-8B (Q5_K_M)	60.2%	0.5029	~6.48 s	~5.9 GB (Serialized)	\$0.00
SLM Compacto (Ultra Leve)	Multilingual-E5-Large	Qwen3-4B (Q4_K_M)	62.5%	0.4764	~6.23 s	~4.7 GB (Coexistência)	\$0.00
Baseline Comercial Nuvem (OpenAI)	Multilingual-E5-Large	RankGPT (gpt-4o-mini)	61.7%	0.4573	~1.74 s	0 GB (Nuvem)	~\$150.00
Baseline 1º Estágio Puro (Sem Rerank)	Multilingual-E5-Large	none	54.7%	0.4031	0.02 s	~2.2 GB	\$0.00

Resultado Científico Central: Todos os modelos locais de re-ranking (BGE-v2-m3, Qwen3-4B e Qwen3-8B) **superaram o modelo comercial da OpenAI (RankGPT gpt-4o-mini)** em MRR@5. Na base E5-Large, o ganho da OpenAI *não atingiu significância estatística* (p = 0.0510), enquanto os modelos locais comprovaram ganho com p < 0.05.

3. Principais Conclusões para o Projeto de Pesquisa (ICT)

- **A Eficácia do Two-Stage RAG:** O re-ranking sobre 20 candidatos elevou o MRR@5 de **0.3887 para 0.5029 (+29.4%)** na base Qwen3-8B e de **0.4031 para 0.4982 (+23.6%)** na base E5-Large.
- **Resgate Expressivo de Passagens Relevantes:** O Hit Rate@5 subiu de 54.7% para **65.6% (+10.9 pontos percentuais)** com o Qwen3-8B, demonstrando que o re-ranking resgata com precisão fragmentos que estavam dispersos nas posições 6 a 20 do pool.
- **Por que Modelos Locais Vencem a OpenAI?** Cross-encoders e SLMs treinados especificamente com função de perda para ranqueamento de passagens (atenção cruzada bidirecional entre tokens) superam LLMs genéricas que reordenam por indução de texto listwise via prompt.
- **Viabilidade Operacional em Workstation e CPU Corporativa:** A quantização em 4 e 5 bits viabilizou modelos de até 8B parâmetros em GPU de 8 GB, enquanto a execução em ONNX INT8 permitiu latência sub-110 ms em CPU comum sem acelerador gráfico.

4. Recomendação de Implantação para a CM Comandos Lineares

Diretriz Arquitetural para Servidor em Produção (CPU sem GPU dedicada):

O servidor corporativo de produção não possui GPU dedicada. Medições empíricas no corpus da CM Comandos comprovam que o **Multilingual-E5-Large em ONNX INT8** atinge **apenas 107 ms na CPU** (< 1.5 GB RAM) com MRR@5 de **0.4031** — superando a API em nuvem da OpenAI (0.3840 a 415 ms) com 1/4 da latência e custo zero. O **Multilingual-E5-Base (ONNX INT8)** roda em 53 ms e o **Nomic-Embed-Text** em 50 ms. Em contrapartida, SLMs generativos de 4B e 8B (Qwen3-Reranker) são *inviáveis em tempo real na CPU* (> 20s por consulta).

1. **Servidor CPU — Opção Principal (Mais Rápida e Confiável)** 🏆: Adotar o 1º Estágio puro com **Multilingual-E5-Large (ONNX INT8)** ou busca híbrida densa + BM25 via Reciprocal Rank Fusion (RRF). *Latência Total: ~110 ms | Zero GPU | RAM: < 2 GB | Custo: \$0.00.* Resposta instantânea e superior à nuvem proprietária.
2. **Servidor CPU — Opção com Re-ranking Leve** ⚡: Empregar **Multilingual-E5-Large (ONNX INT8)** (1º estágio) + Cross-Encoder **BGE-Reranker-v2-m3 (ONNX INT8)** com pool restrito para **\$K_{ext{cand}} = 5\$ ou \$8\$ candidatos** (em vez de 20). *Latência Total: ~1.5s a 2.0s na CPU | Zero GPU.* Alta precisão com tempo aceitável para suporte técnico.
3. **Ambiente Workstation com GPU (Engenharia de Produto e Perícia Avançada):** Em estações com GPU de 8 GB GDDR6, utilizar **Multilingual-E5-Large + BGE-Reranker-v2-m3** (Top-20, ~1.18s, ~3.4 GB VRAM) ou **Qwen3-Reranker-8B (Q5_K_M)** para perícia complexa de inversores (Hit Rate@5 máximo de 65.6%, ~6.5s).