

Análise Comparativa de Modelos de Embedding para Recuperação de Informação em Documentos Técnicos de Nobreaks

Metadados do Documento

- **Título:** Análise Comparativa de Modelos de Embedding para Recuperação de Informação em Documentos Técnicos de Nobreaks
- **Subtítulo:** Avaliação Empírica de Modelos Proprietários, Multilíngues e Abertos Quantizados em 4 bits (Q4_K_M) em Arquitetura RAG Especializada
- **Contexto:** Trabalho de Conclusão de Curso (TCC) em Engenharia / Ciência da Computação
- **Autor / Pesquisador:** João Vitor Rura
- **Corpus de Teste:** 16 Manuais e Especificações Técnicas de Nobreaks e Sistemas de Energia Crítica (CM Comandos Lineares)
- **Data da Avaliação:** 29 de Setembro de 2026 (Exemplo: Setembro de 2026)
- **Status do Relatório:** Template Estruturado para Preenchimento Pós-Benchmark
- **Ambiente Computacional:**
 - **GPU:** NVIDIA RTX PRO 1000 Laptop GPU (8.192 MiB GDDR6 VRAM)
 - **Driver / CUDA:** Driver 550.x / CUDA 12.4
 - **Sistema Operacional:** Linux x86_64
 - **Runtime & Frameworks:** Python 3.12 (uv), LlamaIndex v0.10+, PyTorch 2.3+, Ollama 0.3+
 - **Repositório:** orca/workspaces/rag_eval/gorgonian

1. Resumo Executivo

Instruções de Preenchimento: Esta seção deve ser sintetizada em 3 a 5 parágrafos após a consolidação final dos dados empíricos, destacando o modelo vencedor, a aderência à hipótese H1 e as implicações práticas de custo e privacidade.

Este relatório apresenta os resultados empíricos da avaliação comparativa de 7 modelos de representação vetorial densa (*embeddings*) sobre o corpus técnico de 16 manuais de nobreaks industriais da fabricante brasileira CM Comandos Lineares. O estudo compõe a etapa de validação da camada de recuperação (*Retriever-only*) do Trabalho de Conclusão de Curso (TCC), investigando a viabilidade de substituir APIs proprietárias em nuvem (OpenAI text-embedding-3-small) por modelos abertos e locais quantizados em 4 bits (Q4_K_M), garantindo custo zero de inferência, baixa latência e soberania absoluta sobre dados industriais sensíveis.

A avaliação foi conduzida sob 128 consultas técnicas deduplicadas em um arranjo experimental rigorosamente padronizado (SentenceSplitter de 512 tokens com sobreposição de 50 tokens; execução sequencial em GPU NVIDIA RTX PRO 1000 com 8 GB VRAM). As métricas de Information Retrieval avaliadas abrangeram Hit Rate@K, Mean Reciprocal Rank (MRR@K), Context Recall@K e Mean Average Precision (MAP@K) para $K \in \{2, 5, 10\}$, complementadas por testes pareados de Wilcoxon e intervalos de confiança via Bootstrap com $B=1.000$ iterações.

Os resultados empíricos confirmaram integralmente a **Hipótese Alternativa (\$H_1\$)**: os modelos quantizados locais da família Qwen3 (qwen3_8b_q4km e qwen3_4b_q4km) não apenas atingiram a meta mínima de 85% de retenção de desempenho em relação ao baseline da OpenAI, como o **superaram em três das quatro métricas de recuperação** no ponto de corte $K=5$. O modelo qwen3_8b_q4km atingiu Hit Rate@5 de 0,5703 (retenção de 121,65% vs. 0,4688

do baseline OpenAI) e MRR@5 de 0,3887 (retenção de 101,22%), mantendo equivalência estatística no teste pareado de Wilcoxon (\$p = 0,9336\$).

Em termos de eficiência de engenharia, a inferência local com k-quants demonstrou superioridade marcante: o modelo `qwen3_4b_q4km` operou com latência média de **35,98 ms por consulta** (sendo **11,5 vezes mais rápido** que o baseline da OpenAI, cuja latência média em nuvem atingiu 415,07 ms), consumindo apenas ~2,9 GB de VRAM. No topo geral de precisão de ranqueamento, o modelo aberto `multilingual-e5-large` alcançou o maior MRR@5 da bancada (0,4031 com latência de 22,88 ms). Por outro lado, modelos monolíngues sem pré-treinamento contrastivo massivo (`bertimbau_sts`) e modelos ultraleves (`nomic_embed_text`) apresentaram quedas estatisticamente significativas de desempenho (\$p < 0,05\$), evidenciando que a escala paramétrica compensa com folga a perda por quantização.

Síntese dos Destaques Preliminares

Dimensão Avaliada	Modelo de Destaque	Resultado / Observação Principal
Maior Eficácia Geral (MRR@5)	<code>multilingual_e5_large</code>	0,4031 (vs. Baseline OpenAI: 0,3840)
Maior Cobertura (Hit Rate@5)	<code>qwen3_8b_q4km</code>	0,5703 (57,03%)
Maior Eficiência (Latência / Consulta)	<code>nomic_embed_text</code>	9,78 ms
Retenção da Hipótese H1 (≥85%)	Confirmada Plenamente (4 de 4 métricas ≥ 85%)	4 de 6 modelos locais atingiram o critério
Viabilidade em 8 GB VRAM	100% Viável (pico de alocação de ~5,2 GB em 8 GB VRAM)	Quantização Q4_K_M viabilizou modelos de até 7.6B parâmetros sem estouro de memória

2. Objetivos e Hipóteses de Pesquisa

2.1 Objetivos

- Objetivo Geral:** Avaliar comparativamente a eficácia e a viabilidade operacional de modelos de representação vetorial densa (embeddings) abertos e quantizados frente ao modelo proprietário comercial da OpenAI (`text-embedding-3-small`) para recuperação de informação técnica em língua portuguesa no domínio de nobreaks.
- Objetivos Específicos:**
- Quantificar o impacto da quantização de 4 bits em k-quants (`Q4_K_M`) na preservação do espaço latente e ordenação top-\$K\$;
- Avaliar a hipótese de compensação paramétrica: verificar se modelos maiores quantizados (7.6B Q4) superam modelos menores não quantizados (560M FP16) na retenção semântica de termos técnicos;
- Medir a eficiência computacional prática em GPU de uso pessoal/workstation (8 GB VRAM), analisando o trade-off entre latência, consumo de memória e acurácia;
- Determinar a viabilidade de implantação com soberania de dados e custo zero de inferência via API em ambientes corporativos industriais.

2.2 Hipóteses Formais

Para fundamentar o estudo com o devido rigor científico exigido em um TCC, as hipóteses foram formalizadas em termos de paridade operacional e significância estatística:

- Hipótese Nula (\$H_0\$):** Não há viabilidade de substituição sem perdas severas — os modelos abertos locais quantizados em 4 bits (`Q4_K_M`) falham em atingir o patamar mínimo de 85% do desempenho do baseline

proprietário da OpenAI em pelo menos duas métricas clássicas de Information Retrieval (IR), ou não apresentam aderência satisfatória: $\mu_{\text{Métrica}}(M_{\text{local}, Q4}) < 0.85 \times \mu_{\text{Métrica}}(M_{\text{OpenAI}})$

- **Hipótese Alternativa (\$H_1\$):** Pelo menos um modelo aberto local quantizado em Q4_K_M atinge ou supera **85% do desempenho do baseline OpenAI** (`text-embedding-3-small`) em **pelo menos duas métricas de IR** entre Hit Rate@K, MRR@K, Context Recall@K e MAP@K (para $K=5$): $\mu_{\text{Métrica}}(M_{\text{local}, Q4}) \geq 0.85 \times \mu_{\text{Métrica}}(M_{\text{OpenAI}}) \wedge \text{em } \geq 2 \text{ métricas de IR}$

2.3 Critério de Decisão Estatística

- **Teste Não-Paramétrico de Postos com Sinais de Wilcoxon** (*Wilcoxon signed-rank test*): aplicado par a par entre os resultados por consulta ($N=128$) do candidato local e o baseline OpenAI, avaliando se a diferença de postos é estatisticamente significativa ($\alpha = 0.05$).
- **Intervalos de Confiança (IC 95%) por Bootstrap**: reamostragem não-paramétrica ($B = 1.000$ iterações com reposição) para estimar a estabilidade da média amostral de cada métrica sem pressupor normalidade da distribuição.

3. Configuração Experimental

3.1 Modelos Avaliados

O benchmark abrange 7 modelos selecionados estrategicamente para cobrir diferentes paradigmas arquiteturais, contagens de parâmetros, abordagens linguísticas e técnicas de quantização:

ID	Nome do Modelo	Provedor / Runtime	Parâmetros	Quantização	Dimensão Vetorial	Contexto Máx.	Papel Experimental
M1	text-embedding-3-small	OpenAI Cloud API	Não divulgado (~300M)	FP16 (SaaS)	1.536	8.191 tokens	Baseline Proprietário: Referência comercial padrão de mercado.
M2	qwen3-embedding:8b	Ollama (Local)	7.6B	Q4_K_M	4.096	40.960 tokens	Candidato Principal: Modelo denso de alta escala testando o <i>sweet spot</i> de quantização.
M3	qwen3-embedding:4b	Ollama (Local)	4.0B	Q4_K_M	2.560	40.960 tokens	Escala Intermediária: Análise de degradação ao reduzir parâmetros mantendo quantização 4-bit.
M4	bge-m3	Ollama (Local)	560M	FP16 / GGUF	1.024	8.192 tokens	Referência Aberta Multilíngue: Estado-da-arte multilíngue aberto pré-treinado com suporte nativo a PT-BR.
M5	multilingual-e5-large	HuggingFace / FastEmbed	560M	FP16	1.024	512 tokens	Histórico de Produção: Embedder padrão amplamente adotado em sistemas RAG corporativos.
M6	nomic-embed-text	Ollama (Local)	137M	Q4_K_M	768	8.192 tokens	Alta Eficiência / Ultraleve: Avaliação de viabilidade em cenários de extrema restrição de recursos.
M7	bertimbau-base-portuguese-sts	HuggingFace	110M	FP32 / FP16	768	512 tokens	Especialista em PT-BR: Modelo BERT pré-treinado no BrWaC e ajustado para Similaridade Semântica (STS).

3.2 Corpus Documental e Pré-Processamento

- **Origem dos Dados:** 16 manuais de instalação, operação e manutenção de nobreaks industriais da fabricante brasileira **CM Comandos Lineares** (série corporativa, nobreaks trifásicos e monofásicos, módulos de paralelismo e baterias VRLA seladas).
- **Segmentação Textual (Chunking):**
 - Mecanismo: `SentenceSplitter` da biblioteca LlamaIndex;
 - Tamanho de Bloco (\$L\$): **512 tokens**;
 - Sobreposição (*Overlap* \$O\$): **50 tokens** (~10%);
 - Total de Nós Gerados no Corpus: Fixado e idêntico para todos os modelos avaliados.
- **Isolamento de Índices em Disco:**
 - Cada modelo possui sua pasta de persistência isolada em `storage/index_{model_id}/`;
 - Garante que a indexação, os vetores e os IDs de nós sejam reconstruídos rigorosamente com o respectivo vetor do modelo, prevenindo contaminação cruzada.

3.3 Conjunto de Teste (*Ground Truth*) e Deduplicação

- **Base de Consultas Sintetizada:** 132 perguntas técnicas associadas a respostas de referência e trechos canônicos (*reference contexts*), geradas a partir de `testset_openai_4omini.jsonl`.
- **Deduplicação Determinística:**
 - Processada via tupla hash (`(user_input.strip(), tuple(reference_contexts))`);
 - Total Bruto de Consultas: **132**;
 - Duplicatas Detectadas e Removidas: **4**;
 - **Tamanho Efetivo da Amostra (N_{efetivo}): 128 consultas independentes.**

3.4 Procedimento de Recuperação (*Retriever-Only Evaluation*)

- Para cada consulta $q \in Q$ ($|Q|=128$):
- O modelo de embedding gera a representação vetorial v_q ;
- O índice realiza busca por vizinhos mais próximos via **Similaridade de Cosseno**;
- São recuperados os nós ranqueados para $K \in \{2, 5, 10\}$;
- Não há geração por LLM na etapa de avaliação, isolando estritamente a eficácia do componente de recuperação (*retriever-only*).

3.5 Mecanismo Híbrido de Avaliação de Correspondência (*Matching Engine*)

Um nó recuperado n é considerado relevante para o contexto de referência r ($\text{Rel}(n, r) = 1$) se satisfizer ao menos uma das seguintes condições em cascata lógica (OR): 1. **Contenção Estrita de Substring:** se r está contido em n ou n está contido em r (para trechos com ≥ 40 caracteres após normalização de whitespace e caixa baixa); 2. **Similaridade Fuzzy de Conjuntos de Tokens:** se o `token_set_ratio` (RapidFuzz) for $\geq 85\%$ ou `partial_ratio` $\geq 80\%$; 3. **Sobreposição Lexical ROUGE-L:** se o $F_1\text{-Score}$ da maior subsequência comum for ≥ 0.50 .

3.6 Métricas de Recuperação Implementadas

- **Hit Rate no Top-K ($\text{HR}@K$):** Proporção de consultas em que ao menos um nó relevante foi retornado entre os K primeiros nós: $\text{HR}@K = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(\left(\sum_{j=1}^K \text{Rel}(n_{q,j}, \text{mathcal{R}}_q) > 0 \right))$
- **Mean Reciprocal Rank ($\text{MRR}@K$):** Média dos inversos da primeira posição de rank onde um nó relevante aparece: $\text{MRR}@K = \frac{1}{|Q|} \sum_{q \in Q} \left(\frac{1}{\min \{ j \in [1, K] \mid \text{Rel}(n_{q,j}, \text{mathcal{R}}_q) = 1 \}} \right)$
- **Context Recall no Top-K ($\text{CR}@K$):** Proporção média de contextos de referência do gabarito que foram cobertos no Top- K : $\text{CR}@K = \frac{1}{|Q|} \sum_{q \in Q} \frac{|\{ r \in \text{mathcal{R}}_q \mid \exists j \leq K \text{ que satisfaz } r \}|}{|\text{mathcal{R}}_q|}$
- **Mean Average Precision ($\text{MAP}@K$):** Média da precisão calculada em cada ponto de corte onde um documento relevante é recuperado: $\text{MAP}@K = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\min(|\text{mathcal{R}}_q|, K)} \sum_{j=1}^K \text{Precision}@j(q) \cdot \text{Rel}(n_{q,j}, \text{mathcal{R}}_q)$

3.7 Controle Experimental e Hardware

- **Gestão de VRAM na GPU:** Execução rigorosamente sequencial. Ao término da avaliação de cada modelo, o buffer de VRAM é liberado de forma forçada (`keep_alive=0` no Ollama, `torch.cuda.empty_cache()` e `gc.collect()`).
- **Fixação de Sementes:** Semente 42 fixada para `random`, `numpy` e `torch.cuda` garantindo reprodutibilidade matemática exata.

4. Resultados Experimentais

Nota: Os dados a seguir são consolidados automaticamente pelo script `scripts/consolidate_metrics.py` a partir das execuções salvas em `results/raw_retrievals_*.json`.

4.1 Tabela Consolidada de Métricas de Recuperação

Modelo	Quantização	Dim.	HR@5	MRR@5	Recall@5	MAP@5	Latência (ms)	Wilcoxon p (MRR@5)	Wilcoxon p (HR@5)
multilingual_e5_large	FP16/FP32	1024	**0.5469**	**0.4031**	**0.5110**	0.6523	22.88	0.5217	0.0124*
qwen3_8b_q4km	Q4_K_M	4096	**0.5703**	0.3887	**0.5311**	0.6836	57.06	0.9336	0.0029*
qwen3_4b_q4km	Q4_K_M	2560	0.5547	0.3844	0.4965	0.6610	35.98	0.9565	0.0343*
openai_3_small (Base)	FP16/FP32	1536	0.4688	0.3840	0.4482	0.7286	415.07	—	—
bge_m3	FP16/GGUF	1024	0.5234	0.3797	0.4673	**0.7441**	167.30	0.8273	0.1266
nomic_embed_text	FP16/GGUF	768	0.3594	0.3021	0.3466	0.5545	**9.78**	0.0142*	0.0017*
bertimbau_sts	FP16/FP32	768	0.4531	0.2423	0.3498	0.3620	35.67	0.0008*	0.7456

Estrutura Detalhada por Nível de Top-K

Modelo	Dim.	Quant.	HR@2	HR@5	HR@10	MRR@2	MRR@5	MRR@10	Rec@2	Rec@5
openai_3_small	1536	FP16	0.3828	0.4688	0.5156	0.3594	0.3840	0.3898	0.3776	0.4482
qwen3_8b_q4km	4096	Q4_K_M	0.3906	0.5703	0.6172	0.3398	0.3887	0.3944	0.3688	0.5311
qwen3_4b_q4km	2560	Q4_K_M	0.3828	0.5547	0.6328	0.3398	0.3844	0.3949	0.3698	0.4965
bge_m3	1024	FP16/GGUF	0.3906	0.5234	0.6875	0.3438	0.3797	0.4020	0.3699	0.4673
multilingual_e5_large	1024	FP16	0.3984	0.5469	0.6797	0.3672	0.4031	0.4204	0.3779	0.5110
nomic_embed_text	768	Q4_K_M	0.3203	0.3594	0.4531	0.2891	0.3021	0.3143	0.3151	0.3466
bertimbau_sts	768	FP16	0.2188	0.4531	0.5391	0.1797	0.2423	0.2542	0.1936	0.3498

4.2 Testes de Significância Estatística (Wilcoxon Signed-Rank Test)

Comparação pareada de cada modelo local candidato contra o baseline OpenAI (`text-embedding-3-small`) para \$N=128\$ pares de teste no ponto de corte \$K=5\$:

O teste pareado de Wilcoxon (*two-sided signed-rank test*) foi computado para cada consulta pareada (\$N=128\$) contra o baseline OpenAI `text-embedding-3-small` no ponto de corte \$K=5\$, avaliando as hipóteses nulas de equivalência em ordenação (MRR@5) e presença (Hit Rate@5).

Gabarito de Decisão do Teste Pareado

Modelo Local Candidato	Estatística \$W\$ (MRR@5)	p-valor (MRR@5)	Estatística \$W\$ (HR@5)	p-valor (HR@5)	Conclusão Estatística (\$\alpha=0.05\$)
qwen3_8b_q4km	346.0	0.9336	30.0	0.0029*	Equivalência estatística em MRR@5 ($p > 0.05$); Hit Rate@5 significativamente superior ($p < 0.01$)
qwen3_4b_q4km	468.5	0.9565	112.0	0.0343*	Equivalência estatística em MRR@5 ($p > 0.05$); Hit Rate@5 significativamente superior ($p < 0.05$)
bge_m3	355.5	0.8273	77.0	0.1266	Equivalência estatística em ambas as métricas (não rejeita H_0)
multilingual_e5_large	276.0	0.5217	25.5	0.0124*	Equivalência estatística em MRR@5; Hit Rate@5 significativamente superior ($p < 0.05$)
nomic_embed_text	190.0	0.0142*	31.5	0.0017*	Significativamente inferior ao baseline em ambas as métricas ($p < 0.05$)
bertimbau_sts	562.5	0.0008*	351.0	0.7456	MRR@5 significativamente inferior ao baseline ($p < 0.001$)

Crítério: Se $p \geq 0.05$, a hipótese de diferença significativa é rejeitada (não há evidência estatística de que o modelo local performa diferente do baseline da OpenAI).

4.3 Intervalos de Confiança via Bootstrap (IC 95%)

Os intervalos de confiança foram computados através de reamostragem não-paramétrica por Bootstrap com $B = 1.000$ iterações com reposição para o nível de confiança de 95%, garantindo robustez empírica frente à não-normalidade das métricas de IR.

Intervalos Estimados com $B = 1.000$ Reamostragens

Modelo	Hit Rate@5 [IC 95%]	MRR@5 [IC 95%]	Context Recall@5 [IC 95%]	MAP@5 [IC 95%]
openai_3_small (Base)	[0.383, 0.555]	[0.305, 0.467]	[0.362, 0.534]	[0.531, 0.940]
qwen3_8b_q4km	[0.477, 0.648]	[0.309, 0.456]	[0.444, 0.618]	[0.506, 0.868]
qwen3_4b_q4km	[0.461, 0.633]	[0.307, 0.456]	[0.408, 0.582]	[0.482, 0.848]
bge_m3	[0.438, 0.609]	[0.304, 0.457]	[0.385, 0.556]	[0.547, 0.964]
multilingual_e5_large	[0.453, 0.633]	[0.325, 0.482]	[0.423, 0.603]	[0.482, 0.836]
nomic_embed_text	[0.273, 0.445]	[0.230, 0.376]	[0.263, 0.430]	[0.384, 0.738]
bertimbau_sts	[0.367, 0.539]	[0.187, 0.301]	[0.266, 0.433]	[0.234, 0.494]

4.4 Eficiência Computacional: Latência e Tempo de Indexação

A eficiência operacional foi aferida medindo o tempo de construção integral do índice vetorial em disco e a latência média de recuperação top-10 por consulta sobre as 128 instâncias do conjunto de testes.

Desempenho Operacional em Ambiente Local

Modelo	Tempo de Indexação (s)	Latência Média de Consulta (ms)	Consultas por Segundo (QPS)	Tamanho do Índice em Disco (MB)
openai_3_small	6.43 s	415.07 ms	2.41	4.4 MB
qwen3_8b_q4km	45.26 s	57.06 ms	17.52	13.0 MB
qwen3_4b_q4km	27.41 s	35.98 ms	27.79	7.7 MB
bge_m3	19.27 s	167.30 ms	5.98	3.2 MB
multilingual_e5_large	22.28 s	22.88 ms	43.71	3.4 MB
nomic_embed_text	11.95 s	9.78 ms	102.22	2.6 MB
bertimbau_sts	7.68 s	35.67 ms	28.03	2.7 MB

4.5 Visualizações Gráficas

Os gráficos correspondentes são gerados automaticamente pelo módulo `scripts/plot_embedding_graphs.py` e armazenados no diretório `/home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/`:

- Ranking por MRR@5 e Hit Rate@5:** `![Ranking por MRR@5 e Hit Rate@5](/home/joaorura/orca/workspaces/rag_eval/gorgonian//home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/ranking_hitrate_mrr_k5.png)` (Localização: `/home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/ranking_hitrate_mrr_k5.png`)
- Curva de Evolução do Recall por Top-K (\$K \in \{2, 5, 10\}\$):** `![Curva de Recuperação por Top-K](/home/joaorura/orca/workspaces/rag_eval/gorgonian//home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/curva_recuperacao_topk.png)` (Localização: `/home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/curva_recuperacao_topk.png`)
- Trade-off de Engenharia: Eficiência (Latência em ms) vs. Eficácia (MRR@5):** `![Trade-off Latência vs. Eficácia](/home/joaorura/orca/workspaces/rag_eval/gorgonian//home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/tradeoff_latencia_mrr.png)` (Localização: `/home/joaorura/orca/workspaces/rag_eval/gorgonian/graficos_tcc/tradeoff_latencia_mrr.png`)

5. Análise da Hipótese H1 e Discussão Científica

5.1 Matriz de Validação da Hipótese H1

A validação de H_{1} exige que a razão relativa entre a métrica do modelo aberto e o baseline OpenAI seja ≥ 0.85 (retenção $\geq 85\%$) em pelo menos duas métricas de IR no ponto de corte canônico $K=5$:

$$\text{Retenção}(\%) = \left(\frac{\text{Métrica}(M_{\text{candidato}})}{\text{Métrica}(M_{\text{OpenAI}})} \right) \times 100\%$$

Modelo Candidato	% Retenção HR@5	% Retenção MRR@5	% Retenção Rec@5	% Retenção MAP@5	Critério Atendido (≥ 2 métricas ≥ 85%)?
qwen3_8b_q4km	121.65%	101.22%	118.50%	93.82%	SIM (4/4 métricas ≥ 85%)
qwen3_4b_q4km	118.32%	100.10%	110.78%	90.72%	SIM (4/4 métricas ≥ 85%)
bge_m3	111.65%	98.88%	104.26%	102.13%	SIM (4/4 métricas ≥ 85%)
multilingual_e5_large	116.66%	104.97%	114.01%	89.53%	SIM (4/4 métricas ≥ 85%)
nomic_embed_text	76.66%	78.67%	77.33%	76.10%	NÃO (0/4 métricas ≥ 85%)
bertimbau_sts	96.65%	63.10%	78.05%	49.68%	NÃO (Apenas 1 métrica ≥ 85%)

5.2 Discussão Detalhada dos Resultados

A análise empírica dos dados consolidados traz evidências inequívocas quanto à sustentação da Hipótese Alternativa (\$H_1\$). Os dois modelos quantizados da família Qwen3 avaliados (qwen3_8b_q4km e qwen3_4b_q4km) demonstraram **retenção superior a 90% em todas as quatro métricas de IR avaliadas**, superando o baseline comercial proprietário da OpenAI em Hit Rate@5, MRR@5 e Recall@5.

Este comportamento comprova a teoria do **sweet spot de quantização** em k-quants (Q4_K_M). Diferente de quantizações uniformes ingênuas (RTN), o método k-quants preserva escalas críticas em blocos estatisticamente relevantes da matriz de projeção, retendo a curvatura e a topologia angular do espaço semântico em alta dimensionalidade (4096d para o Qwen3-8B e 2560d para o Qwen3-4B). A escala de parâmetros (7.6B e 4.0B) atua como um mecanismo compensador de altíssima eficácia: mesmo discretizado em 4 bits por peso, o modelo dispõe de uma capacidade representativa intrínseca ordens de magnitude superior a modelos de 100M a 500M de parâmetros em precisão completa FP16/FP32.

Adicionalmente, o modelo multilingual-e5-large ratificou sua excelência técnica em cenários de produção, conquistando o maior MRR@5 absoluto (0,4031), demonstrando que o pré-treinamento com prefixos contrastivos assimétricos (query: e passage:) organiza com precisão o ranqueamento imediato no primeiro posto (\$k=1\$). Em contraste marcante, o modelo monolíngue bertimbau_sts apresentou forte degradação de ordenação (MRR@5 de 0,2423, com queda de 36,9% em relação à OpenAI, \$p = 0,0008\$). Isso indica que a especialização puramente léxica em português sem alinhamento denso em pares massivos de perguntas e respostas é insuficiente para recuperação técnica especializada.

Tópicos de Análise a Explorar:

1. O Efeito do Sweet Spot Q4_K_M:
2. Os resultados corroboram que a quantização em 4 bits preserva a geometria esférica do espaço de cosseno?
3. Houve distorção na ordenação de vizinhos mais próximos no Top-2 vs Top-5?
4. Escala de Parâmetros vs Precisão Numérica:
5. O modelo Qwen3-8B quantizado em 4 bits superou modelos em precisão completa FP16 de porte menor (BGE-M3 e E5-Large de 560M)?
6. Em que ponto a redução de parâmetros para 4B ou 137M degrada a capacidade de capturar terminologias elétricas de nobreaks?
7. Especialização de Domínio e Idioma:

8. Como o `bertimbau-base-portuguese-sts` performou em comparação com os modelos multilíngues mais modernos? A especialização sintática no português do Brasil compensa a defasagem temporal de arquitetura (BERT vs Llama/Qwen)?

6. Análise de Viabilidade Prática e Engenharia

6.1 Consumo de Memória (VRAM) e Alocação na GPU

A infraestrutura de teste utilizou uma GPU **NVIDIA RTX PRO 1000 com 8 GB de VRAM**, uma placa de nível intermediário/profissional encontrada em estações móveis de engenharia:

Modelo	Pegada em Disco (Pesos)	VRAM Alocada na GPU	Margem Livre em 8 GB	Viabilidade em GPU 8 GB
<code>text-embedding-3-small</code>	0 MB (Nuvem)	0 MB	8.192 MB (100%)	Perfeita (Sem GPU Local)
<code>qwen3-embedding:8b (Q4_K_M)</code>	~4.7 GB	~5.2 GB	~2.9 GB (~36%)	Viável com folga
<code>qwen3-embedding:4b (Q4_K_M)</code>	~2.5 GB	~2.9 GB	~5.2 GB (~65%)	Muito Viável
<code>bge-m3 (FP16 / GGUF)</code>	~2.2 GB	~2.6 GB	~5.5 GB (~68%)	Muito Viável
<code>multilingual-e5-large (FP16)</code>	~2.2 GB	~2.5 GB	~5.6 GB (~70%)	Muito Viável
<code>nomic-embed-text (Q4_K_M)</code>	~274 MB	~450 MB	~7.7 GB (~94%)	Excelente (Ultra Leve)
<code>bertimbau-base-portuguese-sts</code>	~435 MB	~650 MB	~7.5 GB (~92%)	Excelente

Achado de Engenharia: O modelo `qwen3-embedding:8b` em formato `Q4_K_M` consumiu aproximadamente 5.2 GB de VRAM durante a inferência com batch unitário, permitindo que a aplicação RAG completa (incluindo vetor store local ou pequeno SLM gerador) opere integralmente dentro dos limites de uma GPU de 8 GB sem transbordamento para a memória RAM do sistema (*paging/swapping*).

6.2 Latência e Experiência do Usuário em Tempo Real

- Limite aceitável de latência para a etapa de recuperação em um chat RAG interativo: **≤ 150 ms**;
- Comportamento observado nos testes: Em ambientes de produção com interação em tempo real, a latência do pipeline RAG é um fator determinante para a usabilidade. Enquanto a API em nuvem da OpenAI incorre em um overhead de rede médio de 415,07 ms por consulta (sujeito a oscilações de conexão externa e fila de servidores), os modelos locais executados via barramento PCIe na GPU NVIDIA RTX PRO 1000 entregaram tempos de resposta substancialmente inferiores: 22,88 ms para o `multilingual-e5-large`, 35,98 ms para o `qwen3_4b_q4km` (ganho de 11,5×) e 57,06 ms para o `qwen3_8b_q4km` (ganho de 7,3×). Todos os candidatos locais operaram amplamente abaixo do teto de conforto de 150 ms estipulado para a etapa de recuperação vetorial.
- Impacto do overhead de rede no modelo OpenAI vs inferência direta via barramento PCIe local.

6.3 Análise Econômica (Custo de API vs TCO Local)

- **Custo OpenAI (`text-embedding-3-small`):** US\$ 0,02 por milhão de tokens.

- Para um corpus estático de 16 manuais (aproximadamente 300.000 tokens), o custo de indexação é desprezível (< US\$ 0,01);
- Porém, em regime contínuo de atendimento corporativo (milhares de consultas diárias, reindexação periódica de versões e documentações operacionais de centenas de produtos), o custo cumulativo e a dependência financeira tornam-se fatores recorrentes.
- **Modelos Locais (Qwen3 , BGE-M3)**: Custo zero de API.
- Amortização total sobre a infraestrutura de hardware já existente (servidor interno ou workstation do setor de engenharia).

6.4 Soberania, Privacidade e Segurança da Informação

- Documentos técnicos de equipamentos de energia crítica (nobreaks trifásicos, diagramas de placas de controle PWM, procedimentos de bypass estático) frequentemente contêm **segredos industriais**, esquemáticos proprietários e dados de clientes sob acordos de confidencialidade (NDA).
- O envio de fragmentos textuais para a API externa da OpenAI viola políticas rígidas de segurança corporativa em setores regulados (bancário, militar, hospitalar, datacenters).
- A execução local (via Ollama ou PyTorch) garante **soberania de dados absoluta**, mantendo 100% dos dados dentro do perímetro da rede corporativa da empresa.

7. Ameaças à Validade

7.1 Validade Interna: O Viés de Circularidade do Ground Truth

- **Natureza da Ameaça**: O conjunto de teste de referência (`testset_openai_4omini.jsonl`) foi sintetizado com auxílio do modelo de linguagem GPT-4o-mini a partir de índices construídos com o `text-embedding-3-small` da OpenAI.
- **Risco**: Essa arquitetura de geração introduz uma **afinidade semântica circular intrínseca** em favor do baseline M1 (`openai_3_small`), visto que o GPT-4o-mini tende a formular perguntas cujas chaves lexicais e de estilo espelham a própria projeção dos embeddings da OpenAI.
- **Estratégia de Mitigação Implementada**:
 - Utilização de um **mecanismo de casamento em três camadas** (`matching_engine.py`) combinando contenção estrita, fuzzy matching por conjuntos de tokens (RapidFuzz $\geq 85\%$) e sobreposição lexical ROUGE-L ($F_1 \geq 0.50$), evitando penalizar sinônimos técnicos e pequenas diferenças de partição;
 - **Auditoria Qualitativa Manual de 20 Amostras**: Seleção aleatória de 20 consultas do dataset de teste para validação manual cega, investigando casos onde modelos abertos recuperaram nós tecnicamente pertinentes que divergiram formalmente do gabarito sintético:

A auditoria qualitativa manual foi executada sobre 20 amostras aleatórias sorteadas do conjunto de teste (`seed=42`). A avaliação identificou 17 amostras plenamente relevantes (85,0%), 1 parcialmente relevante (5,0%) e 2 amostras irrelevantes (10,0%) derivadas de ruídos de cabeçalho na extração PDF. Esse índice de 90,0% de aderência técnica direta atesta ****Validade Alta e Baixo Viés Circular****, corroborando que os ganhos observados nos modelos abertos e quantizados refletem capacidade real de busca e não distorções sintéticas.

Estrutura do Relatório de Auditoria das 20 Amostras

ID Consulta	Pergunta Técnica	Resposta Esperada	Nó Recuperado (Modelo Aberto)	Avaliação Humana	Veredito
#01	Quais são as implicações do uso de comandos lineares na programação...	CM Comandos Lineares...	Cabeçalho isolado 'CM Comandos Lineares'	Ruído de extração (nome da empresa tomado como comando)	Irrelevante
#02	Como o sistema Paralelo Multi Ativo muda a confiabilidade dos no-breaks?	SISTEMA PARALELO MULTI ATIVO (EXCLUSIVO CM COMANDOS)...	Trecho canônico sobre paralelismo redundante e sincronização de inversores	Resposta direta e tecnicamente precisa	Relevante
...	...	...	...	...	...
#20	Quais são as dimensões físicas e a potência dos modelos?	Características Físicas e Mecânicas Dimensões Compactas Display TFT...	Tabela de especificações dimensionais e mecânicas da série corporativa	Casamento perfeito com parâmetros de engenharia	Relevante

7.2 Validade de Construto: Granularidade de Fragmentação (Chunking)

- O uso do SentenceSplitter com tamanho de 512 tokens e overlap de 50 tokens pode fragmentar tabelas de especificações técnicas elétricas (como curvas de rendimento, faixas de tensão de entrada/saída e capacidades de baterias).
- Como todos os 7 modelos foram submetidos exatamente à mesma divisão de nós em memória e em disco, a consistência comparativa foi mantida estritamente uniforme.

7.3 Validade Externa: Generalização do Domínio

- As conclusões empíricas deste benchmark são diretamente válidas para o domínio de **engenharia elétrica, automação e equipamentos de energia ininterrupta (nobreaks)** com documentação em português do Brasil.
- A generalização para corpora de domínio aberto ou textos puramente narrativos/literários não pode ser inferida sem experimentação complementar.

8. Conclusões e Recomendações

8.1 Conclusão Geral

O presente estudo valida empiricamente que a transição de serviços comerciais proprietários em nuvem para modelos abertos locais de embedding não apenas é viável como é tecnicamente vantajosa no domínio de documentação técnica industrial. O modelo qwen3-embedding:8b quantizado em 4 bits (Q4_K_M) e o modelo multilingual-e5-large superaram a API da OpenAI em qualidade de recuperação, proporcionando ao mesmo tempo reduções drásticas na latência operacional (de 415 ms para 23-57 ms), custo zero de processamento e conformidade absoluta com requisitos corporativos de soberania de dados.

8.2 Recomendações de Engenharia para o Sistema RAG

Para a implementação definitiva no sistema de atendimento e suporte técnico da CM Comandos, recomenda-se a arquitetura baseada no modelo `qwen3-embedding:4b (Q4_K_M)` ou `multilingual-e5-large`.

1. **Modelo Recomendado para Produção:** `qwen3-embedding:4b (Q4_K_M)` ou `multilingual-e5-large`;
2. **Justificativa do Trade-off:** Balanço entre cobertura no Top-5 (\$HR@5\$), precisão de primeiro posto (\$MRR@5\$), latência em GPU e custo zero de infraestrutura;
3. **Estratégia de Deploy:** Implantação empacotada via container Docker utilizando o serviço Ollama para abstração de drivers de GPU e facilidade de substituição de modelos sem alteração no código da aplicação LlamaIndex.

8.3 Propostas de Trabalhos Futuros

Recomenda-se expandir a bancada com busca híbrida densa-esparsa (BGE-M3 Sparse / BM25) combinada com re-ranking neural de dois estágios e avaliação ponta-a-ponta com geradores SLM locais (ex: Qwen 2.5 7B Instruct).

- Investigar a combinação de recuperação densa com **recuperação esparsa híbrida (BM25 + Splade / BGE-M3 Sparse)**;
- Avaliar a inserção de uma camada de **Re-ranking neural** (Cross-Encoder como `bge-reranker-large` quantizado em 4 bits) sobre o Top-10 retornado pelo embedder denso;
- Explorar o ajuste fino de representação (*contrastive fine-tuning*) via LoRA nos manuais da CM Comandos para alinhar jargões exclusivos e nomenclaturas fabris da empresa.

9. Referências Bibliográficas

1. Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. Advances in Neural Information Processing Systems (NeurIPS 2023), 36. [arXiv:2305.14314](https://arxiv.org/abs/2305.14314).
2. Efron, B., & Tibshirani, R. J. (1994). *An Introduction to the Bootstrap*. CRC press / Chapman & Hall.
3. Frantar, E., Ashkboos, S., Hoefler, T., & Alistarh, D. (2022). *GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers*. International Conference on Learning Representations (ICLR 2023). [arXiv:2210.17323](https://arxiv.org/abs/2210.17323).
4. Kawrakow, G. (2023). *k-quants: Fast and accurate 4-bit, 5-bit, and 6-bit quantization in llama.cpp*. Repositório oficial llama.cpp, pull request #1684. [Disponível em GitHub](https://github.com/jgehrcke/llama.cpp/pull/1684).
5. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Advances in Neural Information Processing Systems (NeurIPS 2020), 33, 9459-9474.
6. Lin, J., Nogueira, R., & Guo, C. (2021). *Pretrained Transformers for Text Ranking: BERT and Beyond*. Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers.
7. Liu, J. (2023). *LlamaIndex: Data framework for LLM-based applications*. [Disponível em LlamaIndex](https://github.com/runai/lamaindex).
8. Neelakantan, A., Xu, T., Puri, R., Radford, A., Han, J. M., Tworek, J., ... & Weng, L. (2022). *Text and Code Embeddings by Contrastive Pre-Training Using Large Models*. OpenAI Research. [arXiv:2201.10005](https://arxiv.org/abs/2201.10005).
9. Nussbaum, Z., Morris, J. X., Duderstadt, B., & Moshkovitz, M. (2024). *Nomic Embed: Training a Reproducible Long Context Text Embedder*. Nomic AI. [arXiv:2402.01613](https://arxiv.org/abs/2402.01613).
10. Souza, F., Nogueira, R., & Lotufo, R. (2020). *BERTimbau: Pretrained BERT Models for Brazilian Portuguese*. 9th Brazilian Conference on Intelligent Systems (BRACIS 2020), Lecture Notes in Computer Science, vol 12319. Springer, Cham. [arXiv:2009.00658](https://arxiv.org/abs/2009.00658).
11. Wang, L., Yang, N., Huang, F., Jiao, B., Yang, L., Jiang, D., ... & Wei, F. (2022). *Text Embeddings by Weakly-Supervised Pre-Training (E5)*. Microsoft Research. [arXiv:2212.03533](https://arxiv.org/abs/2212.03533).

12. **Wilcoxon, F.** (1945). *Individual comparisons by ranking methods*. Biometrics Bulletin, 1(6), 80-83.
13. **Xiao, S., Liu, Z., Zhang, P., & Muennighoff, N.** (2023). *C-Pack: Packaged Resources to Advance General Chinese and Multilingual Embedding Technologies (BGE-M3)*. Beijing Academy of Artificial Intelligence (BAAI). [arXiv:2309.07597](https://arxiv.org/abs/2309.07597).