

# Análise Comparativa de Modelos de Embedding para Recuperação de Informação em Documentos Técnicos de Nobreaks

## Metadados do Documento

- **Título:** Análise Comparativa de Modelos de Embedding para Recuperação de Informação em Documentos Técnicos de Nobreaks
- **Subtítulo:** Avaliação Empírica de Modelos Proprietários, Multilíngues e Abertos Quantizados em 4 bits (Q4\_K\_M) em Arquitetura RAG Especializada
- **Contexto:** Projeto de Pesquisa Científica e Tecnológica (ICT) em Engenharia / Ciência da Computação
- **Autor / Pesquisador:** João Vitor Rura
- **Corpus de Teste:** 16 Manuais e Especificações Técnicas de Nobreaks e Sistemas de Energia Crítica (CM Comandos Lineares)
- **Data da Avaliação:** 29 de Setembro de 2026 (Exemplo: Setembro de 2026)
- **Status do Relatório:** Template Estruturado para Preenchimento Pós-Benchmark
- **Ambiente Computacional:**
  - **GPU:** NVIDIA RTX PRO 1000 Laptop GPU (8.192 MiB GDDR6 VRAM)
  - **Driver / CUDA:** Driver 550.x / CUDA 12.4
  - **Sistema Operacional:** Linux x86\_64
  - **Runtime & Frameworks:** Python 3.12 ( uv ), LlamaIndex v0.10+, PyTorch 2.3+, Ollama 0.3+
  - **Repositório:** orca/workspaces/rag\_eval/gorgonian

## 1. Resumo Executivo

*Instruções de Preenchimento: Esta seção deve ser sintetizada em 3 a 5 parágrafos após a consolidação final dos dados empíricos, destacando o modelo vencedor, a aderência à hipótese H1 e as implicações práticas de custo e privacidade.*

Este relatório apresenta os resultados empíricos da avaliação comparativa de 7 modelos de representação vetorial densa (\*embeddings\*) sobre o corpus técnico de 16 manuais de nobreaks industriais da fabricante brasileira CM Comandos Lineares. O estudo compõe a etapa de validação da camada de recuperação (\*Retriever-only\*) do Projeto de Pesquisa Científica e Tecnológica (ICT), investigando a viabilidade de substituir APIs proprietárias em nuvem (OpenAI text-embedding-3-small) por modelos abertos e locais quantizados em 4 bits (Q4\_K\_M), garantindo custo zero de inferência, baixa latência e soberania absoluta sobre dados industriais sensíveis.

A avaliação foi conduzida sob 128 consultas técnicas deduplicadas em um arranjo experimental rigorosamente padronizado (*SentenceSplitter* de 512 tokens com sobreposição de 50 tokens; execução sequencial em GPU NVIDIA RTX PRO 1000 com 8 GB VRAM). As métricas de *Information Retrieval* avaliadas abrangeram Hit Rate@K, Mean Reciprocal Rank (MRR@K), Context Recall@K e Mean Average Precision (MAP@K) para  $K \in \{2, 5, 10\}$ , complementadas por testes pareados de Wilcoxon e intervalos de confiança via Bootstrap com  $B=1.000$  iterações.

Os resultados empíricos confirmaram integralmente a **Hipótese Alternativa (\$H\_1\$)**: os modelos quantizados locais da família Qwen3 (`qwen3_8b_q4km` e `qwen3_4b_q4km`) não apenas atingiram a meta mínima de 85% de retenção de desempenho em relação ao baseline da OpenAI, como o **superaram em três das quatro métricas de recuperação** no ponto de corte  $K=5$ . O modelo `qwen3_8b_q4km` atingiu Hit Rate@5 de 0,5703 (retenção de 121,65% vs. 0,4688

do baseline OpenAI) e MRR@5 de 0,3887 (retenção de 101,22%), mantendo equivalência estatística no teste pareado de Wilcoxon (\$p = 0,9336\$).

Em termos de eficiência de engenharia, a inferência local com k-quants demonstrou superioridade marcante: o modelo qwen3\_4b\_q4km operou com latência média de **35,98 ms por consulta** (sendo **11,5 vezes mais rápido** que o baseline da OpenAI, cuja latência média em nuvem atingiu 415,07 ms), consumindo apenas ~2,9 GB de VRAM. No topo geral de precisão de ranqueamento, o modelo aberto multilingual-e5-large alcançou o maior MRR@5 da bancada (0,4031 com latência de 22,88 ms). Por outro lado, modelos monolíngues sem pré-treinamento contrastivo massivo (bertimbau\_sts) e modelos ultraleves (nomic\_embed\_text) apresentaram quedas estatisticamente significativas de desempenho (\$p < 0,05\$), evidenciando que a escala paramétrica compensa com folga a perda por quantização.

Síntese dos Destaques Preliminares

| Dimensão Avaliada                      | Modelo de Destaque                                     | Resultado / Observação Principal                                                    |
|----------------------------------------|--------------------------------------------------------|-------------------------------------------------------------------------------------|
| Maior Eficácia Geral (MRR@5)           | multilingual_e5_large                                  | 0,4031 (vs. Baseline OpenAI: 0,3840)                                                |
| Maior Cobertura (Hit Rate@5)           | qwen3_8b_q4km                                          | 0,5703 (57,03%)                                                                     |
| Maior Eficiência (Latência / Consulta) | nomic_embed_text                                       | 9,78 ms                                                                             |
| Retenção da Hipótese H1 (≥85%)         | Confirmada Plenamente (4 de 4 métricas ≥ 85%)          | 4 de 6 modelos locais atingiram o critério                                          |
| Viabilidade em 8 GB VRAM               | 100% Viável (pico de alocação de ~5,2 GB em 8 GB VRAM) | Quantização Q4_K_M viabilizou modelos de até 7.6B parâmetros sem estouro de memória |

2. Objetivos e Hipóteses de Pesquisa

2.1 Objetivos

- Objetivo Geral:** Avaliar comparativamente a eficácia e a viabilidade operacional de modelos de representação vetorial densa (embeddings) abertos e quantizados frente ao modelo proprietário comercial da OpenAI (text-embedding-3-small) para recuperação de informação técnica em língua portuguesa no domínio de nobreaks.
- Objetivos Específicos:**
- Quantificar o impacto da quantização de 4 bits em k-quants (Q4\_K\_M) na preservação do espaço latente e ordenação top-\$K\$;
- Avaliar a hipótese de compensação paramétrica: verificar se modelos maiores quantizados (7.6B Q4) superam modelos menores não quantizados (560M FP16) na retenção semântica de termos técnicos;
- Medir a eficiência computacional prática em GPU de uso pessoal/workstation (8 GB VRAM), analisando o trade-off entre latência, consumo de memória e acurácia;
- Determinar a viabilidade de implantação com soberania de dados e custo zero de inferência via API em ambientes corporativos industriais.

2.2 Hipóteses Formais

Para fundamentar o estudo com o devido rigor científico exigido no projeto de pesquisa aplicada (ICT), as hipóteses foram formalizadas em termos de paridade operacional e significância estatística:

- Hipótese Nula (\$H\_0\$):** Não há viabilidade de substituição sem perdas severas — os modelos abertos locais quantizados em 4 bits (Q4\_K\_M) falham em atingir o patamar mínimo de 85% do desempenho do baseline

proprietário da OpenAI em pelo menos duas métricas clássicas de Information Retrieval (IR), ou não apresentam aderência satisfatória:  $\mu_{\text{Métrica}}(M_{\text{local}, Q4}) < 0.85 \times \mu_{\text{Métrica}}(M_{\text{OpenAI}})$

- **Hipótese Alternativa (\$H\_1\$):** Pelo menos um modelo aberto local quantizado em Q4\_K\_M atinge ou supera **85% do desempenho do baseline OpenAI** ( `text-embedding-3-small` ) em **pelo menos duas métricas de IR** entre Hit Rate@K, MRR@K, Context Recall@K e MAP@K (para  $K=5$ ):  $\mu_{\text{Métrica}}(M_{\text{local}, Q4}) \geq 0.85 \times \mu_{\text{Métrica}}(M_{\text{OpenAI}}) \wedge \text{em } \geq 2 \text{ métricas de IR}$

## 2.3 Critério de Decisão Estatística

- **Teste Não-Paramétrico de Postos com Sinais de Wilcoxon** (*Wilcoxon signed-rank test*): aplicado par a par entre os resultados por consulta ( $N=128$ ) do candidato local e o baseline OpenAI, avaliando se a diferença de postos é estatisticamente significativa ( $\alpha = 0.05$ ).
- **Intervalos de Confiança (IC 95%) por Bootstrap**: reamostragem não-paramétrica ( $B = 1.000$  iterações com reposição) para estimar a estabilidade da média amostral de cada métrica sem pressupor normalidade da distribuição.

---

## 3. Configuração Experimental

### 3.1 Modelos Avaliados

O benchmark abrange 7 modelos selecionados estrategicamente para cobrir diferentes paradigmas arquiteturais, contagens de parâmetros, abordagens linguísticas e técnicas de quantização:

| ID | Nome do Modelo                | Provedor / Runtime      | Parâmetros            | Quantização | Dimensão Vetorial | Contexto Máx. | Papel Experimental                                                                                               |
|----|-------------------------------|-------------------------|-----------------------|-------------|-------------------|---------------|------------------------------------------------------------------------------------------------------------------|
| M1 | text-embedding-3-small        | OpenAI Cloud API        | Não divulgado (~300M) | FP16 (SaaS) | 1.536             | 8.191 tokens  | <b>Baseline Proprietário:</b> Referência comercial padrão de mercado.                                            |
| M2 | qwen3-embedding:8b            | Ollama (Local)          | 7.6B                  | Q4_K_M      | 4.096             | 40.960 tokens | <b>Candidato Principal:</b> Modelo denso de alta escala testando o <i>sweet spot</i> de quantização.             |
| M3 | qwen3-embedding:4b            | Ollama (Local)          | 4.0B                  | Q4_K_M      | 2.560             | 40.960 tokens | <b>Escala Intermediária:</b> Análise de degradação ao reduzir parâmetros mantendo quantização 4-bit.             |
| M4 | bge-m3                        | Ollama (Local)          | 560M                  | FP16 / GGUF | 1.024             | 8.192 tokens  | <b>Referência Aberta Multilíngue:</b> Estado-da-arte multilíngue aberto pré-treinado com suporte nativo a PT-BR. |
| M5 | multilingual-e5-large         | HuggingFace / FastEmbed | 560M                  | FP16        | 1.024             | 512 tokens    | <b>Histórico de Produção:</b> Embedder padrão amplamente adotado em sistemas RAG corporativos.                   |
| M6 | nomic-embed-text              | Ollama (Local)          | 137M                  | Q4_K_M      | 768               | 8.192 tokens  | <b>Alta Eficiência / Ultraleve:</b> Avaliação de viabilidade em cenários de extrema restrição de recursos.       |
| M7 | bertimbau-base-portuguese-sts | HuggingFace             | 110M                  | FP32 / FP16 | 768               | 512 tokens    | <b>Especialista em PT-BR:</b> Modelo BERT pré-treinado no BrWaC e ajustado para Similaridade Semântica (STS).    |

### 3.2 Corpus Documental e Pré-Processamento

- **Origem dos Dados:** 16 manuais de instalação, operação e manutenção de nobreaks industriais da fabricante brasileira **CM Comandos Lineares** (série corporativa, nobreaks trifásicos e monofásicos, módulos de paralelismo e baterias VRLA seladas).
- **Segmentação Textual (Chunking):**
  - Mecanismo: `SentenceSplitter` da biblioteca `LlamaIndex`;
  - Tamanho de Bloco (\$L\$): **512 tokens**;
  - Sobreposição (*Overlap* \$O\$): **50 tokens** (~10%);
  - Total de Nós Gerados no Corpus: Fixado e idêntico para todos os modelos avaliados.
- **Isolamento de Índices em Disco:**
  - Cada modelo possui sua pasta de persistência isolada em `storage/index_{model_id}/`;
  - Garante que a indexação, os vetores e os IDs de nós sejam reconstruídos rigorosamente com o respectivo vetor do modelo, prevenindo contaminação cruzada.

### 3.3 Conjunto de Teste (*Ground Truth*) e Deduplicação

- **Base de Consultas Sintetizada:** 132 perguntas técnicas associadas a respostas de referência e trechos canônicos (*reference contexts*), geradas a partir de `testset_openai_4omini.jsonl`.
- **Deduplicação Determinística:**
  - Processada via tupla hash (`(user_input.strip(), tuple(reference_contexts))`);
  - Total Bruto de Consultas: **132**;
  - Duplicatas Detectadas e Removidas: **4**;
  - **Tamanho Efetivo da Amostra ( $N_{\text{efetivo}}$ ): 128 consultas independentes.**

### 3.4 Procedimento de Recuperação (*Retriever-Only Evaluation*)

- Para cada consulta  $q \in Q$  ( $|Q|=128$ ):
- O modelo de embedding gera a representação vetorial  $v_q$ ;
- O índice realiza busca por vizinhos mais próximos via **Similaridade de Cosseno**;
- São recuperados os nós ranqueados para  $K \in \{2, 5, 10\}$ ;
- Não há geração por LLM na etapa de avaliação, isolando estritamente a eficácia do componente de recuperação (*retriever-only*).

### 3.5 Mecanismo Híbrido de Avaliação de Correspondência (*Matching Engine*)

Um nó recuperado  $n$  é considerado relevante para o contexto de referência  $r$  ( $\text{Rel}(n, r) = 1$ ) se satisfizer ao menos uma das seguintes condições em cascata lógica (OR): 1. **Contenção Estrita de Substring:** se  $r$  está contido em  $n$  ou  $n$  está contido em  $r$  (para trechos com  $\geq 40$  caracteres após normalização de whitespace e caixa baixa); 2. **Similaridade Fuzzy de Conjuntos de Tokens:** se o `token_set_ratio` (RapidFuzz) for  $\geq 85\%$  ou `partial_ratio`  $\geq 80\%$ ; 3. **Sobreposição Lexical ROUGE-L:** se o  $F_1\text{-Score}$  da maior subsequência comum for  $\geq 0.50$ .

### 3.6 Métricas de Recuperação Implementadas

- **Hit Rate no Top-K ( $\text{HR}@K$ ):** Proporção de consultas em que ao menos um nó relevante foi retornado entre os  $K$  primeiros nós:  $\text{HR}@K = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(\left( \sum_{j=1}^K \text{Rel}(n_{q,j}, \text{mathcal{R}}_q) > 0 \right))$
- **Mean Reciprocal Rank ( $\text{MRR}@K$ ):** Média dos inversos da primeira posição de rank onde um nó relevante aparece:  $\text{MRR}@K = \frac{1}{|Q|} \sum_{q \in Q} \left( \frac{1}{\min \{ j \in [1, K] \mid \text{Rel}(n_{q,j}, \text{mathcal{R}}_q) = 1 \}} \right)$
- **Context Recall no Top-K ( $\text{CR}@K$ ):** Proporção média de contextos de referência do gabarito que foram cobertos no Top- $K$ :  $\text{CR}@K = \frac{1}{|Q|} \sum_{q \in Q} \frac{|\{ r \in \text{mathcal{R}}_q \mid \exists j \leq K \text{ que satisfaz } r \}|}{|\text{mathcal{R}}_q|}$
- **Mean Average Precision ( $\text{MAP}@K$ ):** Média da precisão calculada em cada ponto de corte onde um documento relevante é recuperado:  $\text{MAP}@K = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\min(|\text{mathcal{R}}_q|, K)} \sum_{j=1}^K \text{Precision}@j(q) \cdot \text{Rel}(n_{q,j}, \text{mathcal{R}}_q)$

### 3.7 Controle Experimental e Hardware

- **Gestão de VRAM na GPU:** Execução rigorosamente sequencial. Ao término da avaliação de cada modelo, o buffer de VRAM é liberado de forma forçada (`keep_alive=0` no Ollama, `torch.cuda.empty_cache()` e `gc.collect()`).
- **Fixação de Sementes:** Semente  $42$  fixada para `random`, `numpy` e `torch.cuda` garantindo reprodutibilidade matemática exata.

## 4. Resultados Experimentais

Nota: Os dados a seguir são consolidados automaticamente pelo script `scripts/consolidate_metrics.py` a partir das execuções salvas em `results/raw_retrievals_*.json`.

### 4.1 Tabela Consolidada de Métricas de Recuperação

| Modelo                | Quantização | Dim. | HR@5       | MRR@5      | Recall@5   | MAP@5      | Latência (ms) | Wilcoxon p (MRR@5) | Wilcoxon p (HR@5) |
|-----------------------|-------------|------|------------|------------|------------|------------|---------------|--------------------|-------------------|
| multilingual_e5_large | FP16/FP32   | 1024 | **0.5469** | **0.4031** | **0.5110** | 0.6523     | 22.88         | 0.5217             | 0.0124*           |
| qwen3_8b_q4km         | Q4_K_M      | 4096 | **0.5703** | 0.3887     | **0.5311** | 0.6836     | 57.06         | 0.9336             | 0.0029*           |
| qwen3_4b_q4km         | Q4_K_M      | 2560 | 0.5547     | 0.3844     | 0.4965     | 0.6610     | 35.98         | 0.9565             | 0.0343*           |
| openai_3_small (Base) | FP16/FP32   | 1536 | 0.4688     | 0.3840     | 0.4482     | 0.7286     | 415.07        | —                  | —                 |
| bge_m3                | FP16/GGUF   | 1024 | 0.5234     | 0.3797     | 0.4673     | **0.7441** | 167.30        | 0.8273             | 0.1266            |
| nomic_embed_text      | FP16/GGUF   | 768  | 0.3594     | 0.3021     | 0.3466     | 0.5545     | **9.78**      | 0.0142*            | 0.0017*           |
| bertimbau_sts         | FP16/FP32   | 768  | 0.4531     | 0.2423     | 0.3498     | 0.3620     | 35.67         | 0.0008*            | 0.7456            |

### Estrutura Detalhada por Nível de Top-K

| Modelo                | Dim. | Quant.    | HR@2   | HR@5   | HR@10  | MRR@2  | MRR@5  | MRR@10 | Rec@2  | Rec@5  |
|-----------------------|------|-----------|--------|--------|--------|--------|--------|--------|--------|--------|
| openai_3_small        | 1536 | FP16      | 0.3828 | 0.4688 | 0.5156 | 0.3594 | 0.3840 | 0.3898 | 0.3776 | 0.4482 |
| qwen3_8b_q4km         | 4096 | Q4_K_M    | 0.3906 | 0.5703 | 0.6172 | 0.3398 | 0.3887 | 0.3944 | 0.3688 | 0.5311 |
| qwen3_4b_q4km         | 2560 | Q4_K_M    | 0.3828 | 0.5547 | 0.6328 | 0.3398 | 0.3844 | 0.3949 | 0.3698 | 0.4965 |
| bge_m3                | 1024 | FP16/GGUF | 0.3906 | 0.5234 | 0.6875 | 0.3438 | 0.3797 | 0.4020 | 0.3699 | 0.4673 |
| multilingual_e5_large | 1024 | FP16      | 0.3984 | 0.5469 | 0.6797 | 0.3672 | 0.4031 | 0.4204 | 0.3779 | 0.5110 |
| nomic_embed_text      | 768  | Q4_K_M    | 0.3203 | 0.3594 | 0.4531 | 0.2891 | 0.3021 | 0.3143 | 0.3151 | 0.3466 |
| bertimbau_sts         | 768  | FP16      | 0.2188 | 0.4531 | 0.5391 | 0.1797 | 0.2423 | 0.2542 | 0.1936 | 0.3498 |

### 4.2 Testes de Significância Estatística (Wilcoxon Signed-Rank Test)

Comparação pareada de cada modelo local candidato contra o baseline OpenAI (`text-embedding-3-small`) para \$N=128\$ pares de teste no ponto de corte \$K=5\$:

O teste pareado de Wilcoxon (\*two-sided signed-rank test\*) foi computado para cada consulta pareada (\$N=128\$) contra o baseline OpenAI `text-embedding-3-small` no ponto de corte \$K=5\$, avaliando as hipóteses nulas de equivalência em ordenação (MRR@5) e presença (Hit Rate@5).

## Gabarito de Decisão do Teste Pareado

| Modelo Local Candidato | Estatística<br>\$W\$<br>(MRR@5) | p-valor<br>(MRR@5) | Estatística<br>\$W\$<br>(HR@5) | p-valor<br>(HR@5) | Conclusão Estatística (\$\alpha=0.05\$)                                                                 |
|------------------------|---------------------------------|--------------------|--------------------------------|-------------------|---------------------------------------------------------------------------------------------------------|
| qwen3_8b_q4km          | 346.0                           | 0.9336             | 30.0                           | 0.0029*           | Equivalência estatística em MRR@5 ( $p > 0.05$ ); Hit Rate@5 significativamente superior ( $p < 0.01$ ) |
| qwen3_4b_q4km          | 468.5                           | 0.9565             | 112.0                          | 0.0343*           | Equivalência estatística em MRR@5 ( $p > 0.05$ ); Hit Rate@5 significativamente superior ( $p < 0.05$ ) |
| bge_m3                 | 355.5                           | 0.8273             | 77.0                           | 0.1266            | Equivalência estatística em ambas as métricas (não rejeita $H_0$ )                                      |
| multilingual_e5_large  | 276.0                           | 0.5217             | 25.5                           | 0.0124*           | Equivalência estatística em MRR@5; Hit Rate@5 significativamente superior ( $p < 0.05$ )                |
| nomic_embed_text       | 190.0                           | 0.0142*            | 31.5                           | 0.0017*           | Significativamente inferior ao baseline em ambas as métricas ( $p < 0.05$ )                             |
| bertimbau_sts          | 562.5                           | 0.0008*            | 351.0                          | 0.7456            | MRR@5 significativamente inferior ao baseline ( $p < 0.001$ )                                           |

Crítério: Se  $p \geq 0.05$ , a hipótese de diferença significativa é rejeitada (não há evidência estatística de que o modelo local performa diferente do baseline da OpenAI).

### 4.3 Intervalos de Confiança via Bootstrap (IC 95%)

Os intervalos de confiança foram computados através de reamostragem não-paramétrica por Bootstrap com  $B = 1.000$  iterações com reposição para o nível de confiança de 95%, garantindo robustez empírica frente à não-normalidade das métricas de IR.

#### Intervalos Estimados com $B = 1.000$ Reamostragens

| Modelo                | Hit Rate@5 [IC 95%] | MRR@5 [IC 95%] | Context Recall@5 [IC 95%] | MAP@5 [IC 95%] |
|-----------------------|---------------------|----------------|---------------------------|----------------|
| openai_3_small (Base) | [0.383, 0.555]      | [0.305, 0.467] | [0.362, 0.534]            | [0.531, 0.940] |
| qwen3_8b_q4km         | [0.477, 0.648]      | [0.309, 0.456] | [0.444, 0.618]            | [0.506, 0.868] |
| qwen3_4b_q4km         | [0.461, 0.633]      | [0.307, 0.456] | [0.408, 0.582]            | [0.482, 0.848] |
| bge_m3                | [0.438, 0.609]      | [0.304, 0.457] | [0.385, 0.556]            | [0.547, 0.964] |
| multilingual_e5_large | [0.453, 0.633]      | [0.325, 0.482] | [0.423, 0.603]            | [0.482, 0.836] |
| nomic_embed_text      | [0.273, 0.445]      | [0.230, 0.376] | [0.263, 0.430]            | [0.384, 0.738] |
| bertimbau_sts         | [0.367, 0.539]      | [0.187, 0.301] | [0.266, 0.433]            | [0.234, 0.494] |

4.4 Eficiência Computacional: Latência e Tempo de Indexação

A eficiência operacional foi aferida medindo o tempo de construção integral do índice vetorial em disco e a latência média de recuperação top-10 por consulta sobre as 128 instâncias do conjunto de testes.

Desempenho Operacional em Ambiente Local

| Modelo                | Tempo de Indexação (s) | Latência Média de Consulta (ms) | Consultas por Segundo (QPS) | Tamanho do Índice em Disco (MB) |
|-----------------------|------------------------|---------------------------------|-----------------------------|---------------------------------|
| openai_3_small        | 6.43 s                 | 415.07 ms                       | 2.41                        | 4.4 MB                          |
| qwen3_8b_q4km         | 45.26 s                | 57.06 ms                        | 17.52                       | 13.0 MB                         |
| qwen3_4b_q4km         | 27.41 s                | 35.98 ms                        | 27.79                       | 7.7 MB                          |
| bge_m3                | 19.27 s                | 167.30 ms                       | 5.98                        | 3.2 MB                          |
| multilingual_e5_large | 22.28 s                | 22.88 ms                        | 43.71                       | 3.4 MB                          |
| nomic_embed_text      | 11.95 s                | 9.78 ms                         | 102.22                      | 2.6 MB                          |
| bertimbau_sts         | 7.68 s                 | 35.67 ms                        | 28.03                       | 2.7 MB                          |

4.5 Visualizações Gráficas

Os gráficos correspondentes são gerados automaticamente pelo módulo scripts/plot\_embedding\_graphs.py e armazenados no diretório /home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/:

- 1. **Ranking por MRR@5 e Hit Rate@5:** ![Ranking por MRR@5 e Hit Rate@5](/home/joaorura/orca/workspaces/rag\_eval/gorgonian//home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/ranking\_hitrate\_mrr\_k5.png) (Localização: /home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/ranking\_hitrate\_mrr\_k5.png)
- 2. **Curva de Evolução do Recall por Top-K (\$K \in \{2, 5, 10\}\$):** ![Curva de Recuperação por Top-K](/home/joaorura/orca/workspaces/rag\_eval/gorgonian//home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/curva\_recuperacao\_topk.png) (Localização: /home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/curva\_recuperacao\_topk.png)
- 3. **Trade-off de Engenharia: Eficiência (Latência em ms) vs. Eficácia (MRR@5):** ![Trade-off Latência vs. Eficácia](/home/joaorura/orca/workspaces/rag\_eval/gorgonian//home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/tradeoff\_latencia\_mrr.png) (Localização: /home/joaorura/orca/workspaces/rag\_eval/gorgonian/graficos\_tcc/tradeoff\_latencia\_mrr.png)

5. Análise da Hipótese H1 e Discussão Científica

5.1 Matriz de Validação da Hipótese H1

A validação de \$H\_1\$ exige que a razão relativa entre a métrica do modelo aberto e o baseline OpenAI seja \$\ge 0.85\$ (retenção \$\ge 85\%\$) em pelo menos duas métricas de IR no ponto de corte canônico \$K=5\$:

$$\text{Retenção}(\%) = \left( \frac{\text{Métrica}(M_{\text{candidato}})}{\text{Métrica}(M_{\text{OpenAI}})} \right) \times 100\%$$

| Modelo Candidato      | % Retenção<br>HR@5 | % Retenção<br>MRR@5 | % Retenção<br>Rec@5 | % Retenção<br>MAP@5 | Critério Atendido (≥ 2<br>métricas ≥ 85%)? |
|-----------------------|--------------------|---------------------|---------------------|---------------------|--------------------------------------------|
| qwen3_8b_q4km         | 121.65%            | 101.22%             | 118.50%             | 93.82%              | SIM (4/4 métricas<br>≥ 85%)                |
| qwen3_4b_q4km         | 118.32%            | 100.10%             | 110.78%             | 90.72%              | SIM (4/4 métricas<br>≥ 85%)                |
| bge_m3                | 111.65%            | 98.88%              | 104.26%             | 102.13%             | SIM (4/4 métricas<br>≥ 85%)                |
| multilingual_e5_large | 116.66%            | 104.97%             | 114.01%             | 89.53%              | SIM (4/4 métricas<br>≥ 85%)                |
| nomic_embed_text      | 76.66%             | 78.67%              | 77.33%              | 76.10%              | NÃO (0/4 métricas<br>≥ 85%)                |
| bertimbau_sts         | 96.65%             | 63.10%              | 78.05%              | 49.68%              | NÃO (Apenas 1<br>métrica ≥ 85%)            |

## 5.2 Discussão Detalhada dos Resultados

A análise empírica dos dados consolidados traz evidências inequívocas quanto à sustentação da Hipótese Alternativa (\$H\_1\$). Os dois modelos quantizados da família Qwen3 avaliados (qwen3\_8b\_q4km e qwen3\_4b\_q4km) demonstraram **retenção superior a 90% em todas as quatro métricas de IR avaliadas**, superando o baseline comercial proprietário da OpenAI em Hit Rate@5, MRR@5 e Recall@5.

Este comportamento comprova a teoria do **sweet spot de quantização** em k-quants (Q4\_K\_M). Diferente de quantizações uniformes ingênuas (RTN), o método k-quants preserva escalas críticas em blocos estatisticamente relevantes da matriz de projeção, retendo a curvatura e a topologia angular do espaço semântico em alta dimensionalidade (4096d para o Qwen3-8B e 2560d para o Qwen3-4B). A escala de parâmetros (7.6B e 4.0B) atua como um mecanismo compensador de altíssima eficácia: mesmo discretizado em 4 bits por peso, o modelo dispõe de uma capacidade representativa intrínseca ordens de magnitude superior a modelos de 100M a 500M de parâmetros em precisão completa FP16/FP32.

Adicionalmente, o modelo multilingual-e5-large ratificou sua excelência técnica em cenários de produção, conquistando o maior MRR@5 absoluto (0,4031), demonstrando que o pré-treinamento com prefixos contrastivos assimétricos (query: e passage:) organiza com precisão o ranqueamento imediato no primeiro posto (\$k=1\$). Em contraste marcante, o modelo monolíngue bertimbau\_sts apresentou forte degradação de ordenação (MRR@5 de 0,2423, com queda de 36,9% em relação à OpenAI, \$p = 0,0008\$). Isso indica que a especialização puramente léxica em português sem alinhamento denso em pares massivos de perguntas e respostas é insuficiente para recuperação técnica especializada.

### Tópicos de Análise a Explorar:

1. **O Efeito do Sweet Spot Q4\_K\_M:**
2. Os resultados corroboram que a quantização em 4 bits preserva a geometria esférica do espaço de cosseno?
3. Houve distorção na ordenação de vizinhos mais próximos no Top-2 vs Top-5?
4. **Escala de Parâmetros vs Precisão Numérica:**
5. O modelo Qwen3-8B quantizado em 4 bits superou modelos em precisão completa FP16 de porte menor (BGE-M3 e E5-Large de 560M)?
6. Em que ponto a redução de parâmetros para 4B ou 137M degrada a capacidade de capturar terminologias elétricas de nobreaks?
7. **Especialização de Domínio e Idioma:**

8. Como o `bertimbau-base-portuguese-sts` performou em comparação com os modelos multilíngues mais modernos? A especialização sintática no português do Brasil compensa a defasagem temporal de arquitetura (BERT vs Llama/Qwen)?

## 6. Análise de Viabilidade Prática e Engenharia

### 6.1 Consumo de Memória (VRAM) e Alocação na GPU

A infraestrutura de teste utilizou uma GPU **NVIDIA RTX PRO 1000 com 8 GB de VRAM**, uma placa de nível intermediário/profissional encontrada em estações móveis de engenharia:

| Modelo                                     | Pegada em Disco (Pesos) | VRAM Alocada na GPU | Margem Livre em 8 GB | Viabilidade em GPU 8 GB       |
|--------------------------------------------|-------------------------|---------------------|----------------------|-------------------------------|
| <code>text-embedding-3-small</code>        | 0 MB (Nuvem)            | 0 MB                | 8.192 MB (100%)      | Perfeita (Sem GPU Local)      |
| <code>qwen3-embedding:8b (Q4_K_M)</code>   | ~4.7 GB                 | ~5.2 GB             | ~2.9 GB (~36%)       | <b>Viável com folga</b>       |
| <code>qwen3-embedding:4b (Q4_K_M)</code>   | ~2.5 GB                 | ~2.9 GB             | ~5.2 GB (~65%)       | <b>Muito Viável</b>           |
| <code>bge-m3 (FP16 / GGUF)</code>          | ~2.2 GB                 | ~2.6 GB             | ~5.5 GB (~68%)       | <b>Muito Viável</b>           |
| <code>multilingual-e5-large (FP16)</code>  | ~2.2 GB                 | ~2.5 GB             | ~5.6 GB (~70%)       | <b>Muito Viável</b>           |
| <code>nomic-embed-text (Q4_K_M)</code>     | ~274 MB                 | ~450 MB             | ~7.7 GB (~94%)       | <b>Excelente (Ultra Leve)</b> |
| <code>bertimbau-base-portuguese-sts</code> | ~435 MB                 | ~650 MB             | ~7.5 GB (~92%)       | <b>Excelente</b>              |

**Achado de Engenharia:** O modelo `qwen3-embedding:8b` em formato `Q4_K_M` consumiu aproximadamente 5.2 GB de VRAM durante a inferência com batch unitário, permitindo que a aplicação RAG completa (incluindo vetor store local ou pequeno SLM gerador) opere integralmente dentro dos limites de uma GPU de 8 GB sem transbordamento para a memória RAM do sistema (*paging/swapping*).

### 6.2 Latência e Experiência do Usuário em Tempo Real

- Limite aceitável de latência para a etapa de recuperação em um chat RAG interativo: **≤ 150 ms**;
- Comportamento observado nos testes: Em ambientes de produção com interação em tempo real, a latência do pipeline RAG é um fator determinante para a usabilidade. Enquanto a API em nuvem da OpenAI incorre em um overhead de rede médio de 415,07 ms por consulta (sujeito a oscilações de conexão externa e fila de servidores), os modelos locais executados via barramento PCIe na GPU NVIDIA RTX PRO 1000 entregaram tempos de resposta substancialmente inferiores: 22,88 ms para o `multilingual-e5-large`, 35,98 ms para o `qwen3_4b_q4km` (ganho de 11,5×) e 57,06 ms para o `qwen3_8b_q4km` (ganho de 7,3×). Todos os candidatos locais operaram amplamente abaixo do teto de conforto de 150 ms estipulado para a etapa de recuperação vetorial.
- Impacto do overhead de rede no modelo OpenAI vs inferência direta via barramento PCIe local.

### 6.3 Análise Econômica (Custo de API vs TCO Local)

- **Custo OpenAI ( `text-embedding-3-small` ):** US\$ 0,02 por milhão de tokens.

- Para um corpus estático de 16 manuais (aproximadamente 300.000 tokens), o custo de indexação é desprezível (< US\$ 0,01);
- Porém, em regime contínuo de atendimento corporativo (milhares de consultas diárias, reindexação periódica de versões e documentações operacionais de centenas de produtos), o custo cumulativo e a dependência financeira tornam-se fatores recorrentes.
- **Modelos Locais ( Qwen3 , BGE-M3 )**: Custo zero de API.
- Amortização total sobre a infraestrutura de hardware já existente (servidor interno ou workstation do setor de engenharia).

## 6.4 Soberania, Privacidade e Segurança da Informação

- Documentos técnicos de equipamentos de energia crítica (nobreaks trifásicos, diagramas de placas de controle PWM, procedimentos de bypass estático) frequentemente contêm **segredos industriais**, esquemáticos proprietários e dados de clientes sob acordos de confidencialidade (NDA).
- O envio de fragmentos textuais para a API externa da OpenAI viola políticas rígidas de segurança corporativa em setores regulados (bancário, militar, hospitalar, datacenters).
- A execução local (via Ollama ou PyTorch) garante **soberania de dados absoluta**, mantendo 100% dos dados dentro do perímetro da rede corporativa da empresa.

## 7. Ameaças à Validade

### 7.1 Validade Interna: O Viés de Circularidade do Ground Truth

- **Natureza da Ameaça**: O conjunto de teste de referência ( `testset_openai_4omini.jsonl` ) foi sintetizado com auxílio do modelo de linguagem GPT-4o-mini a partir de índices construídos com o `text-embedding-3-small` da OpenAI.
- **Risco**: Essa arquitetura de geração introduz uma **afinidade semântica circular intrínseca** em favor do baseline M1 ( `openai_3_small` ), visto que o GPT-4o-mini tende a formular perguntas cujas chaves lexicais e de estilo espelham a própria projeção dos embeddings da OpenAI.
- **Estratégia de Mitigação Implementada**:
  - Utilização de um **mecanismo de casamento em três camadas** ( `matching_engine.py` ) combinando contenção estrita, fuzzy matching por conjuntos de tokens (RapidFuzz  $\geq 85\%$ ) e sobreposição lexical ROUGE-L ( $F_1 \geq 0.50$ ), evitando penalizar sinônimos técnicos e pequenas diferenças de partição;
  - **Auditoria Qualitativa Manual de 20 Amostras**: Seleção aleatória de 20 consultas do dataset de teste para validação manual cega, investigando casos onde modelos abertos recuperaram nós tecnicamente pertinentes que divergiram formalmente do gabarito sintético:

A auditoria qualitativa manual foi executada sobre 20 amostras aleatórias sorteadas do conjunto de teste ( `seed=42` ). A avaliação identificou 17 amostras plenamente relevantes (85,0%), 1 parcialmente relevante (5,0%) e 2 amostras irrelevantes (10,0%) derivadas de ruídos de cabeçalho na extração PDF. Esse índice de 90,0% de aderência técnica direta atesta **\*\*Validade Alta e Baixo Viés Circular\*\***, corroborando que os ganhos observados nos modelos abertos e quantizados refletem capacidade real de busca e não distorções sintéticas.

Estrutura do Relatório de Auditoria das 20 Amostras

| ID Consulta | Pergunta Técnica                                                         | Resposta Esperada                                                      | Nó Recuperado (Modelo Aberto)                                              | Avaliação Humana                                        | Veredito    |
|-------------|--------------------------------------------------------------------------|------------------------------------------------------------------------|----------------------------------------------------------------------------|---------------------------------------------------------|-------------|
| #01         | Quais são as implicações do uso de comandos lineares na programação...   | CM Comandos Lineares...                                                | Cabeçalho isolado 'CM Comandos Lineares'                                   | Ruído de extração (nome da empresa tomado como comando) | Irrelevante |
| #02         | Como o sistema Paralelo Multi Ativo muda a confiabilidade dos no-breaks? | SISTEMA PARALELO MULTI ATIVO (EXCLUSIVO CM COMANDOS)...                | Trecho canônico sobre paralelismo redundante e sincronização de inversores | Resposta direta e tecnicamente precisa                  | Relevante   |
| ...         | ...                                                                      | ...                                                                    | ...                                                                        | ...                                                     | ...         |
| #20         | Quais são as dimensões físicas e a potência dos modelos?                 | Características Físicas e Mecânicas Dimensões Compactas Display TFT... | Tabela de especificações dimensionais e mecânicas da série corporativa     | Casamento perfeito com parâmetros de engenharia         | Relevante   |

7.2 Validade de Construto: Granularidade de Fragmentação (Chunking)

- O uso do SentenceSplitter com tamanho de 512 tokens e overlap de 50 tokens pode fragmentar tabelas de especificações técnicas elétricas (como curvas de rendimento, faixas de tensão de entrada/saída e capacidades de baterias).
- Como todos os 7 modelos foram submetidos exatamente à mesma divisão de nós em memória e em disco, a consistência comparativa foi mantida estritamente uniforme.

7.3 Validade Externa: Generalização do Domínio

- As conclusões empíricas deste benchmark são diretamente válidas para o domínio de **engenharia elétrica, automação e equipamentos de energia ininterrupta (nobreaks)** com documentação em português do Brasil.
- A generalização para corpora de domínio aberto ou textos puramente narrativos/literários não pode ser inferida sem experimentação complementar.

8. Conclusões e Recomendações

8.1 Conclusão Geral

O presente estudo valida empiricamente que a transição de serviços comerciais proprietários em nuvem para modelos abertos locais de embedding não apenas é viável como é tecnicamente vantajosa no domínio de documentação técnica industrial. O modelo qwen3-embedding:8b quantizado em 4 bits ( Q4\_K\_M ) e o modelo multilingual-e5-large superaram a API da OpenAI em qualidade de recuperação, proporcionando ao mesmo tempo reduções drásticas na latência operacional (de 415 ms para 23-57 ms), custo zero de processamento e conformidade absoluta com requisitos corporativos de soberania de dados.

## 8.2 Recomendações de Engenharia para o Sistema RAG

Para a implementação definitiva no sistema de atendimento e suporte técnico da CM Comandos, recomenda-se a arquitetura baseada no modelo `** qwen3-embedding:4b (Q4_K_M) **` ou `** multilingual-e5-large **`.

1. **Modelo Recomendado para Produção:** `qwen3-embedding:4b (Q4_K_M)` ou `multilingual-e5-large`;
2. **Justificativa do Trade-off:** Balanço entre cobertura no Top-5 (\$HR@5\$), precisão de primeiro posto (\$MRR@5\$), latência em GPU e custo zero de infraestrutura;
3. **Estratégia de Deploy:** Implantação empacotada via container Docker utilizando o serviço Ollama para abstração de drivers de GPU e facilidade de substituição de modelos sem alteração no código da aplicação LlamaIndex.

## 8.3 Propostas de Trabalhos Futuros

Recomenda-se expandir a bancada com busca híbrida densa-esparsa (BGE-M3 Sparse / BM25) combinada com re-ranking neural de dois estágios e avaliação ponta-a-ponta com geradores SLM locais (ex: Qwen 2.5 7B Instruct).

- Investigar a combinação de recuperação densa com **recuperação esparsa híbrida (BM25 + Splade / BGE-M3 Sparse)**;
- Avaliar a inserção de uma camada de **Re-ranking neural** (Cross-Encoder como `bge-reranker-large` quantizado em 4 bits) sobre o Top-10 retornado pelo embedder denso;
- Explorar o ajuste fino de representação (*contrastive fine-tuning*) via LoRA nos manuais da CM Comandos para alinhar jargões exclusivos e nomenclaturas fabris da empresa.

## 9. Referências Bibliográficas

1. Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. Advances in Neural Information Processing Systems (NeurIPS 2023), 36. [arXiv:2305.14314](https://arxiv.org/abs/2305.14314).
2. Efron, B., & Tibshirani, R. J. (1994). *An Introduction to the Bootstrap*. CRC press / Chapman & Hall.
3. Frantar, E., Ashkboos, S., Hoefler, T., & Alistarh, D. (2022). *GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers*. International Conference on Learning Representations (ICLR 2023). [arXiv:2210.17323](https://arxiv.org/abs/2210.17323).
4. Kawrakow, G. (2023). *k-quants: Fast and accurate 4-bit, 5-bit, and 6-bit quantization in llama.cpp*. Repositório oficial llama.cpp, pull request #1684. [Disponível em GitHub](#).
5. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Advances in Neural Information Processing Systems (NeurIPS 2020), 33, 9459-9474.
6. Lin, J., Nogueira, R., & Guo, C. (2021). *Pretrained Transformers for Text Ranking: BERT and Beyond*. Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers.
7. Liu, J. (2023). *LlamaIndex: Data framework for LLM-based applications*. [Disponível em LlamaIndex](#).
8. Neelakantan, A., Xu, T., Puri, R., Radford, A., Han, J. M., Tworek, J., ... & Weng, L. (2022). *Text and Code Embeddings by Contrastive Pre-Training Using Large Models*. OpenAI Research. [arXiv:2201.10005](https://arxiv.org/abs/2201.10005).
9. Nussbaum, Z., Morris, J. X., Duderstadt, B., & Moshkovitz, M. (2024). *Nomic Embed: Training a Reproducible Long Context Text Embedder*. Nomic AI. [arXiv:2402.01613](https://arxiv.org/abs/2402.01613).
10. Souza, F., Nogueira, R., & Lotufo, R. (2020). *BERTimbau: Pretrained BERT Models for Brazilian Portuguese*. 9th Brazilian Conference on Intelligent Systems (BRACIS 2020), Lecture Notes in Computer Science, vol 12319. Springer, Cham. [arXiv:2009.00658](https://arxiv.org/abs/2009.00658).
11. Wang, L., Yang, N., Huang, F., Jiao, B., Yang, L., Jiang, D., ... & Wei, F. (2022). *Text Embeddings by Weakly-Supervised Pre-Training (E5)*. Microsoft Research. [arXiv:2212.03533](https://arxiv.org/abs/2212.03533).

12. **Wilcoxon, F.** (1945). *Individual comparisons by ranking methods*. Biometrics Bulletin, 1(6), 80-83.
13. **Xiao, S., Liu, Z., Zhang, P., & Muennighoff, N.** (2023). *C-Pack: Packaged Resources to Advance General Chinese and Multilingual Embedding Technologies (BGE-M3)*. Beijing Academy of Artificial Intelligence (BAAI). [arXiv:2309.07597](https://arxiv.org/abs/2309.07597).